

# SESSION 4 SUMMARY

Victor Miguel Terrón Macias

21/1/2021

## SESSION 4. ALGUNAS DISTRIBUCIONES, TEOREMA CENTRAL DEL LÍMITE Y CONTRASTE DE HIPOTESIS

### CONCEPTOS DE ESTADÍSTICA INFERENCIAL BÁSICOS

#### DISTRIBUCIÓN BINOMIAL

Se define como un experimento con las siguientes características: \* Consiste en un número fijo,  $n$ , de pruebas idénticas. \* Cada prueba resulta en uno de dos resultados: éxito  $S$  o fracaso  $F$  \* La probabilidad de éxito en una sola prueba es igual a algún valor  $p$  y es la misma de una prueba a otra. La probabilidad de fracaso es igual a  $q = 1 - p$  \* Las pruebas son independientes \* La variable aleatoria (v.a.discreta) de interés es  $Y$ , el número de éxitos observado durante las  $n$  pruebas.

Se dice que una variable aleatoria  $Y$  tiene una distribución binomial basada en  $n$  pruebas con probabilidad  $p$  de éxito, si y solo si.

$$P_x = \binom{n}{x} p^x q^{n-x}$$

De donde  $P$  es probabilidad binomial, de donde  $x$  es el numero de veces para obtener un resultado específico en  $n$  ensayos, de donde  $\binom{n}{x}$ , de donde  $p$  es la probabilidad de exito en un solo ensayo,  $q$  es probabilidad de fallo en un solo ensayo y  $n$  es el numero de ensayos. Y donde  $P$  que es la posibilidad tiene que cumplir con  $0 \leq P \leq 1$

#### EJEMPLO DE APLICACION DE DISTRIBUCION BINOMIAL

La última novela de un autor ha tenido un gran éxito, hasta el punto de que el 80% de los lectores ya la han leído. Hallar la probabilidad de que en un grupo de 4 amigos que son aficionados a la lectura, 2 hayan leído la novela.

1. Hallar la probabilidad de que una persona haya leído el libro es de 0.8, por lo que la probabilidad de que no lo haya leído es de 0.2. De donde tenemos los siguientes datos:  $n = 4, k = 2, p = 0.8, q = 0.2$
2. Hallar la probabilidad de que máximo 2 personas del grupo de 4 amigos hayan leído la novela: tenemos los siguientes datos:

$$P(x \leq 2) = P(x = 0) + P(x = 1) + P(x = 2)$$

Sustituyendo los datos en la fórmula de distribución binomial tenemos lo siguiente:

$$P_{x \leq 2} = \binom{4}{0} (0.8)^0 (0.2)^{4-0} + \binom{4}{1} (0.8)^1 (0.2)^{4-1} + \binom{4}{2} (0.8)^2 (0.2)^{4-2} = 0.1808$$

## DISTRIBUCIÓN NORMAL

A una distribución normal se le conoce como distribución Gaussiana o distribución de Laplace Gauss. Se utiliza solamente con variables continuas (variables que pueden tomar un número infinito de valores entre dos valores cualesquiera de una característica).

Su gráfica es en forma de campana y simétrica respecto de un determinado parámetro estadístico. Este tipo de distribución propicia el modelado de numerosos fenómenos naturales, sociales y psicológicos. El centro de la campana es el promedio. La desviación estándar nos indican que tan dispersos o separados están los datos con respecto a la media.

Para calcular la probabilidad normal se divide la cantidad de casos favorables entre la cantidad de datos totales, para ello se utiliza la siguiente fórmula:

$$z = \frac{x - \mu}{\sigma}$$

De donde tenemos que  $x$  es el valor de la condición y  $\mu$  es el promedio también conocido como media y  $\sigma$  es la desviación estándar. Manualmente podríamos calcularlo con las tablas de distribución normal.

Las funciones de densidad de probabilidad (de variables aleatorias continuas) cumplen con las siguientes propiedades:

- El área bajo la curva de la función de densidad de probabilidad es igual a 1
- La probabilidad de que  $X$  se encuentre en determinado intervalo  $(a, b)$  es igual al área bajo la curva entre los puntos  $a$  y  $b$ .
- $P(X = c) = 0$  para cualquier valor  $c$  para el que se encuentre definida la función de densidad.

La función de densidad de probabilidad de una variable aleatoria  $x$  que se distribuye como normal con media  $\mu$  y desviación estándar  $\sigma$  es:

$$f(x) = \frac{1}{\sigma \cdot \sqrt{2\pi}} e^{-\frac{(x - \mu)^2}{(2\sigma)^2}}$$

## DISTRIBUCIÓN $t$ DE STUDENT

La función de densidad  $t$  de Student se define como:

En el caso de la distribución  $t$  la media  $\mu = 0$  y

$$\sigma^2 = \frac{v}{(v - 2)}$$

para  $v > 2$  respectivamente.

La apariencia general de la distribución  $t$  es similar a la de la distribución normal estándar: ambas son simétricas y unimodales, y el valor máximo de la ordenada se alcanza en la media  $\mu = 0$ . Sin embargo, la distribución  $t$  tiene colas más amplias que la normal; esto es, la probabilidad de las colas es mayor que en la distribución normal. A medida que el número de grados de libertad tiende a infinito, la forma límite de la distribución  $t$  es la distribución normal estándar.

## Densidad Normal




Figure 1: Distribución normal

## PROPIEDADES DE LA DISTRIBUCIÓN $t$ DE STUDENT

- Cada curva tiene forma de campana con centro en 0.
- Cada curva  $t$  está más dispersa que la curva normal estandar  $z$
- A medida que  $v$  aumenta, la distribución de la curva  $t$  correspondiente disminuye
- A medida que  $v \rightarrow \infty$  la secuencia de curvas  $t$  se aproxima a la curva normal estandar, por lo que la curva  $z$  recibe a veces el nombre de curva  $t$  con grados de libertad  $(gl)gl = \infty$ .

La distribución de la variable aleatoria  $t$  está dada por:

$$f(t) = \frac{\Gamma\left(\frac{v+1}{2}\right)}{\Gamma\left(\frac{v}{2}\right) \cdot \sqrt{\pi v \sigma}} \cdot \left(1 + \frac{1}{v} \left(\frac{x - \mu}{\sigma}\right)^2\right)^{-\frac{v+1}{2}}$$

De donde debemos recordar que  $\sigma^2$  corresponde a varianza y no desviación estandar. Y que  $v$  son los grados de libertad.

La formula de la varianza es:

$$\sigma^2 \cdot \frac{v}{v-2}$$

, la moda es  $= \mu$

## TEOREMA DEL LÍMITE CENTRAL

Sean  $y_1, y_2, \dots, y_n$  variables aleatorias independientes y distribuidas idénticamente con  $E(y_i) = \mu$  y  $V(y_i) = \sigma^2 < \infty$ . Definamos:

$$U_n = \frac{\sum_{i=1}^n y_i - n\mu}{\sigma\sqrt{n}} = \frac{\bar{y} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

Entonces la función de distribución de  $U_n$  converge hacia la función de distribución normal estándar cuando  $n \rightarrow \infty$ . Esto es:

$$P(U_n) = \int_{-\infty}^u \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{t^2}{2}} dt$$

Para toda  $u$ . Es decir que  $\bar{y}$ , está distribuida normalmente en forma asintótica con media  $\mu$  y varianza

$$\frac{\sigma^2}{n}$$

.

El teorema central del límite se puede aplicar a una muestra aleatoria  $y_1, y_2, \dots, y_n$  para cualquier distribución mientras  $E(y_i) = \mu$  y  $V(y_i) = \sigma^2$  sean finitas y el tamaño muestral sea grande.

## ESTIMADORES PUNTUALES INSESGADOS COMUNES

**DEFINICIÓN** Un estimador es una regla, a menudo expresada como una fórmula, que indica cómo calcular el valor de una estimación con base en las mediciones contenidas en una muestra.




Figure 2: Densidad t de student con 7 GDL

**Definición.** Si  $\hat{\theta}$  es un estimador puntual de un parámetro  $\theta$ , entonces  $\hat{\theta}$  es un estimador insesgado si  $E(\hat{\theta}) = \theta$ . Si  $E(\hat{\theta}) \neq \theta$ , se dice que  $\hat{\theta}$  está sesgado.

Valores esperados y errores estándar de algunos estimadores puntuales comunes				
Parámetro objetivo $\theta$	Tamaño(s) muestral(es)	Estimador puntual $\hat{\theta}$	$E(\hat{\theta})$	Error estándar $\sigma_{\hat{\theta}}$
$\mu$	$n$	$\bar{Y}$	$\mu$	$\frac{\sigma}{\sqrt{n}}$
$p$	$n$	$\hat{p} = \frac{y}{n}$	$p$	$\sqrt{\frac{pq}{n}}$
$\mu_1 - \mu_2$	$n_1$ y $n_2$	$\bar{Y}_1 - \bar{Y}_2$	$\mu_1 - \mu_2$	$\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$
$p_1 - p_2$	$n_1$ y $n_2$	$\hat{p}_1 - \hat{p}_2$	$p_1 - p_2$	$\sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}$
$\sigma_1^2$ y $\sigma_2^2$ son las varianzas de las poblaciones 1 y 2, respectivamente.				
Se supone que las dos muestras son independientes.				

Figure 3: valores esperados y errores estándar de algunos estimadores puntuales comunes

## CONTRASTE DE HIPOTESIS

Los elementos de un contraste de hipótesis son: \* Hipótesis nula,  $H_0$  \* Hipótesis alternativa,  $H_a$  \* Estadístico de prueba \* Región de rechazo


**Nota:** También llamaremos prueba de hipótesis a un contraste de hipótesis, sin caer en discusiones formales. Buscamos decidirnos por una de las hipótesis y no estamos exentos de cometer errores.

**Definición.** Se comete un *error tipo I* si  $H_0$  es rechazada cuando  $H_0$  es verdadera. La *probabilidad de un error tipo I* está denotada por  $\alpha$ . El valor de  $\alpha$  se denomina *nivel de la prueba*.

Se comete un *error tipo II* si  $H_0$  es aceptada cuando  $H_a$  es verdadera. La probabilidad de un *error tipo II* está denotada por  $\beta$ .

### Error tipo I y tipo II

$H_0$ : No hay embarazo vs  $H_a$ : Hay embarazo



## CONTRASTES COMUNES CON MUESTRAS GRANDES

Suponga que deseamos contrastar un conjunto de hipótesis respecto a un parámetro con base a una muestra aleatoria  $Y_1, Y_2, \dots, Y_n$ . En esta sección desarrollaremos procedimientos de contrastes de hipótesis que están basados en un estimador que tiene una distribución muestral normal (aproximadamente) con media y error estándar.

Si 0 es un valor específico de, podemos probar  $H_0: \theta = 0$  contra  $H_a: \theta > 0$ . En este caso, las hipótesis nula y alternativa, el estadístico de prueba y la región de rechazo son como sigue:

$$H_0 : \theta = \theta_0 .$$

$$H_a : \theta > \theta_0 .$$

Estadístico de prueba:  $\hat{\theta}$  .

Región de rechazo:  $RR = \{ \hat{\theta} > k \}$ , para alguna selección de  $k$ .

El valor real de  $k$  en la región de rechazo  $RR$  se determina al fijar la probabilidad  $\alpha$  de error tipo I (el nivel de la prueba) y escoger  $k$  de conformidad. Si  $H_0$  es verdadera,  $\hat{\theta}$  tiene una distribución aproximadamente normal con media  $\theta_0$  y error estándar  $\sigma_{\hat{\theta}}$  .

Por tanto, si deseamos una prueba de nivel  $\alpha$  ,

$$k = \theta_0 + z_{\alpha} \sigma_{\hat{\theta}}$$

Es la selección apropiada para  $k$  [si  $Z$  tiene una distribución normal estándar, entonces  $Z_{\alpha}$  es tal que  $P(Z > Z_{\alpha}) = \alpha$ ].

Figure 4: A

## CONTRASTES DE HIPOTESIS DE NIVEL PARA MUESTRAS GRANDES

¿Cómo decidir cuál hipótesis alternativa usar para una prueba? La respuesta depende de la hipótesis que pretendemos apoyar. Si estamos interesados sólo en detectar un aumento en el porcentaje de piezas defectuosas, por ejemplo, debemos localizar la región de rechazo en la cola superior de la distribución normal estándar. Por otra parte, si deseamos detectar un cambio en  $p$  ya sea arriba o debajo de  $p=0.10$ , debemos localizar la región de rechazo en ambas colas de la distribución normal estándar y emplear una prueba de dos colas.



$$H_0 : \theta = \theta_0 .$$

$$H_a : \{ \theta > \theta_0 \text{ (alternativa de cola superior)} . \theta < \theta_0 \text{ (alternativa de cola inferior)} . \theta \neq \theta_0 \text{ (alternativa de dos colas)} .$$

Estadístico de prueba:

$$Z = \frac{\hat{\theta} - \theta_0}{\sigma_{\hat{\theta}}}$$

Región de rechazo:

$$\{ \{ z > z_{\alpha} \} \text{ (RR de cola superior)} . \{ z < -z_{\alpha} \} \text{ (RR de cola inferior)} . \{ |z| > z_{\frac{\alpha}{2}} \} \text{ (RR de dos colas)} .$$

Figure 5: B

### Contraste de hipótesis con muestras pequeñas para $\mu$ y $\mu_1 - \mu_2$

Supongamos que  $Y_1, Y_2, \dots, Y_n$  denotan una muestra aleatoria de tamaño  $n$  de una distribución normal con media  $\mu$  desconocida y varianza  $\sigma^2$  desconocida. Si  $\bar{Y}$  y  $S$  denotan la media muestral y la desviación estándar muestral, respectivamente, y si  $H_0 : \mu = \mu_0$  es verdadera, entonces

$$T = \frac{\bar{Y} - \mu_0}{S/\sqrt{n}}$$

Tiene una distribución  $t$  con  $n-1$  grados de libertad.

Figure 6: C

### Contraste de muestra pequeña para $\mu$

Suposiciones:  $Y_1, Y_2, \dots, Y_n$  constituyen una muestra aleatoria de una distribución normal con  $E(Y_i) = \mu$ .

$$H_0 : \mu = \mu_0.$$

$$H_a : \{\mu > \mu_0 \text{ (alternativa de cola superior)} \cdot \mu < \mu_0 \text{ (alternativa de cola inferior)} \cdot \mu \neq \mu_0 \text{ (alternativa de dos colas)}\}.$$

$$\text{Estadístico de prueba: } T = \frac{\bar{Y} - \mu_0}{S/\sqrt{n}}.$$

Región de rechazo:

$$\{t > t_\alpha \text{ (RR de cola superior)} \cdot t < -t_\alpha \text{ (RR de cola inferior)} \cdot |t| > t_{\alpha/2} \text{ (RR de dos colas)}\}.$$

Figure 7: D

### Contrastes con muestras pequeñas para comparar dos medias poblacionales

Suposiciones: muestras independientes de distribuciones normales con  $\sigma_1^2 = \sigma_2^2$ .

$$H_0 : \mu_1 - \mu_2 = D_0. \text{ Donde } D_0 \text{ es un número fijo.}$$

$$H_a : \{\mu_1 - \mu_2 > D_0 \text{ (alternativa de cola superior)} \cdot \mu_1 - \mu_2 < D_0 \text{ (alternativa de cola inferior)}\}.$$

$$\mu_1 - \mu_2 \neq D_0 \quad (\text{alternativa de dos colas})$$

Estadístico de prueba:

$$T = \frac{\bar{Y}_1 - \bar{Y}_2 - D_0}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

Donde  $T$  tiene una distribución  $t$  de Student con  $n_1 + n_2 - 2$  grados de libertad y

$$S_p = \sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}}$$

Figure 8: E

Estadístico de prueba:

$$T = \frac{\bar{Y}_1 - \bar{Y}_2 - D_0}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

Donde  $T$  tiene una distribución  $t$  de Student con  $n_1 + n_2 - 2$  grados de libertad y

$$S_p = \sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}}$$

Región de rechazo:

$\{t > t_\alpha \text{ (RR de cola superior)}\} \cup \{t < -t_\alpha \text{ (RR de cola inferior)}\} \cup \{|t| > t_{\alpha/2} \text{ (RR de dos colas)}\}.$

Aquí,  $P(T > t_\alpha) = \alpha.$

Figure 9: F

## WORK

Estudiar algunas distribuciones de probabilidad muy comunes y útiles, obtener estimaciones puntuales con propiedades deseables utilizando algunos estimadores insesgados comunes. Llevar a cabo contrastes de hipótesis que ayuden a tomar decisiones.

En esta sesión estudiaremos temas relacionados con los siguientes puntos:

- Cálculo de probabilidades y cuantiles de las distribuciones binomial, normal y  $t$  de Student
- Generación de muestras aleatorias de las distribuciones estudiadas
- Estudio del teorema central del límite mediante simulaciones
- Propiedades de algunos estimadores puntuales insesgados comunes
- Contraste de hipótesis con muestras grandes y pequeñas

## EJEMPLO 1 SESION 4. DISTRIBUCIONES BINOMIAL, NORMAL Y $T$ DE STUDENT

### OBJETIVO

- Aprender a obtener probabilidades, cuantiles y muestras aleatorias relacionadas con las distribuciones binomial, normal y  $t$  de Student
- Interpretar las probabilidades cuando se condieren las gráficas de las funciones de probabilidad y de densidad

### REQUISITOS

- Tener R y Rstudio instalados
- Haber leído el pre-work

## DESARROLLO

```
library(ggplot2) # Utilizaremos estos paquetes para algunas gráficas
library(reshape2)
```

## DISTRIBUCION BINOMIAL

En el caso de la **Distribución binomial** En R para calcular valores de las funciones de probabilidad, distribución o cuantiles de la distribución binomial (discreta), usamos las funciones *dbinom*, *pbinom* y *qbinom* respectivamente. Para generar muestras aleatorias de esta distribución utilizamos la función *rbinom*.

Consideremos un experimento binomial con  $n = 30$  pruebas idénticas e independientes, en donde la probabilidad de éxito en cada prueba es  $p = 0.2$  (parámetros  $n = 30$  y  $p = 0.2$ ) 1. Suponga que realiza un examen de opción múltiple con 30 preguntas, en donde cada pregunta tiene 5 posibles respuestas, pero solo una es correcta siempre. Si elige la respuesta al azar en cada pregunta, y estamos interesados en el número de respuestas correctas obtenidas al final ¿Podemos decir que estamos ante un experimento binomial?

## FUNCIÓN DE PROBABILIDAD

Para obtener  $P(X = 20)$ , es decir, la probabilidad de observar 20 éxitos exactamente, en R ejecutamos:

```
dbinom(x = 20, size = 30, prob = 0.2)
```

```
[1] 3.382768e-08
```

Para obtener  $P(x \leq 20)$ , es decir, la probabilidad de observar a lo mucho 20 exitos o menos ejecutamos:

```
pbinom(x<=20, size = 30, prob = 0.2)
```

La diferencia entre *dbinom()* y *pbinom()* es que *dbinom()* me dice cuál es la probabilidad de que  $Pr(X = x)$  mientras que *pbinom()* te calcula la probabilidad de que  $Pr(X \leq x)$

Para encontrar el valor más pequeño  $b$  tal que  $P(X \leq b) \geq 0.35$ , es decir, el cuantil de orden 0.35, usamos:

## CUANTILES

```
qbinom(p = 0.35, size = 30, prob = 0.2) # b = 5

pbinom(q = 4, size = 30, prob = 0.2) # P(X <= 4) = 0.2552 < 0.35
pbinom(q = 5, size = 30, prob = 0.2) # P(X <= 5) = 0.4275 >= 0.35
pbinom(q = 6, size = 30, prob = 0.2) # P(X <= 6) = 0.6070 >= 0.35
```

```
[1] 5
[1] 0.2552333
[1] 0.4275124
[1] 0.6069699
```

## MUESTRAS ALEATORIAS

Para obtener una muestra aleatoria de tamaño  $n = 1000$ , de la distribución binomial con parámetros como especificamos, hacemos

```
set.seed(4857) # Establecemos una semilla,  
# para poder reproducir la muestra en el futuro  
muestra <- rbinom(n = 1000, size = 30, prob = 0.2)  
length(muestra); muestra[1:3]
```

```
[1] 1000  
[1] 4 7 8
```

Podemos observar las frecuencias absolutas de los distintos valores obtenidos

```
as.data.frame(table(muestra))
```

	muestra	Freq
1	0	1
2	1	8
3	2	31
4	3	77
5	4	132
6	5	161
7	6	196
8	7	146
9	8	126
10	9	65
11	10	30
12	11	13
13	12	10
14	13	2
15	15	2

También podemos observar las frecuencias relativas:

```
(df1 <- as.data.frame(table(muestra)/length(muestra)))  
  
valg <- as.character(df1$muestra) # distintos valores generados por rbinom  
(valg <- as.numeric(valg)) # Convertimos a números
```

	muestra	Freq
1	0	0.001
2	1	0.008
3	2	0.031
4	3	0.077
5	4	0.132
6	5	0.161
7	6	0.196
8	7	0.146
9	8	0.126
10	9	0.065

```

11      10 0.030
12      11 0.013
13      12 0.010
14      13 0.002
15      15 0.002
[1]  0  1  2  3  4  5  6  7  8  9 10 11 12 13 15

```

Las frecuencias relativas son muy parecidas a las siguientes probabilidades

```
(v1 <- round(sapply(valg, dbinom, size = 30, p = 0.2), 3))
```

```

[1] 0.001 0.009 0.034 0.079 0.133 0.172 0.179 0.154 0.111 0.068 0.035 0.016
[13] 0.006 0.002 0.000

```

Combinamos y unimos en un solo dataframe *df1* y *v1*

```

(df2 <- cbind(df1, v1))
(names(df2) <- c("Exitos", "FR", "Prob"))

(df2 <- melt(df2)) # función del paquete reshape2

```

Using Exitos as id variables

```

      muestra  Freq   v1
1          0 0.001 0.001
2          1 0.008 0.009
3          2 0.031 0.034
4          3 0.077 0.079
5          4 0.132 0.133
6          5 0.161 0.172
7          6 0.196 0.179
8          7 0.146 0.154
9          8 0.126 0.111
10         9 0.065 0.068
11        10 0.030 0.035
12        11 0.013 0.016
13        12 0.010 0.006
14        13 0.002 0.002
15        15 0.002 0.000
[1] "Exitos" "FR"      "Prob"
      Exitos variable value
1          0      FR 0.001
2          1      FR 0.008
3          2      FR 0.031
4          3      FR 0.077
5          4      FR 0.132
6          5      FR 0.161
7          6      FR 0.196
8          7      FR 0.146
9          8      FR 0.126
10         9      FR 0.065
11        10      FR 0.030


```

12	11	FR	0.013
13	12	FR	0.010
14	13	FR	0.002
15	15	FR	0.002
16	0	Prob	0.001
17	1	Prob	0.009
18	2	Prob	0.034
19	3	Prob	0.079
20	4	Prob	0.133
21	5	Prob	0.172
22	6	Prob	0.179
23	7	Prob	0.154
24	8	Prob	0.111
25	9	Prob	0.068
26	10	Prob	0.035
27	11	Prob	0.016
28	12	Prob	0.006
29	13	Prob	0.002
30	15	Prob	0.000

Melt en cierta forma une los dataframes en uno solo pero basandose en ciertas condiciones

Las frecuencias relativas son muy parecidas a las probabilidades:

```
ggplot(df2, aes(x = Exitos, y = value, fill = variable)) +
  geom_bar (stat="identity", position = "dodge")
```



```
# Funciones del paquete ggplot2
```

## DISTRIBUCIÓN NORMAL

En R para calcular valores de las funciones de densidad, distribución o cuantiles de la distribución normal (continua), usamos las funciones *dnorm*, *pnorm* y *qnorm* respectivamente. Para generar muestras aleatorias de esta distribución utilizamos la función *rnorm*.

Consideremos una variable aleatoria (v.a.)  $X$  que se distribuye como normal con media 175 y desviación estándar 6 (parámetros  $\mu = 175$  y  $\sigma = 6$ ).

## FUNCIÓN DE DENSIDAD

La función de densidad sirve para caracterizar el comportamiento probable de una población en tanto específica la posibilidad relativa de que una variable aleatoria continuas  $X$  tome un valor cercano a  $x$ .

Densidad significa que la suma de todas las áreas del histograma deben ser igual a 1. La función de densidad es el contorno. Es una línea continua que representa la distribución de densidad de TODA LA POBLACIÓN.

## FUNCIÓN DE DISTRIBUCIÓN

La función de distribución asocia a cada valor de la variable aleatoria la probabilidad acumulada hasta ese valor, por ejemplo: Calcular la función de distribución de probabilidad de las puntuaciones obtenidas al lanzar un dado.

X	$P_i$
$x < 1$	0
$1 \leq x < 2$	$\frac{1}{6}$
$2 \leq x < 3$	$\frac{2}{6}$
$3 \leq x < 4$	$\frac{3}{6}$
$4 \leq x < 5$	$\frac{4}{6}$
$5 \leq x < 6$	$\frac{5}{6}$
$x \leq 6$	1

Siguiendo con el ejemplo disponible en el work tenemos lo siguiente:

Para obtener  $P(x \leq 180)$ , es decir, la probabilidad de que  $X$  tome un valor menor o igual a 180, ejecutamos:

```
x <- seq(-4, 4, 0.01)*6 + 175 # Algunos posibles
# valores que puede tomar la v.a.
# X (mínimo: mu-4sigma, máximo: mu+4sigma)
```




```

y <- dnorm(x, mean = 175, sd = 6) # Valores
# correspondientes de la función de
# densidad de probabilidad
plot(x, y, type = "l", xlab = "", ylab = "")#Te grafica
# en forma de campana los valores de x y y
title(main = "Densidad de Probabilidad Normal",
      sub = expression(paste(mu == 175, " y ", sigma == 6)))#Agrega leyendas
#a gráfico
abline(v = 175, lwd = 2, lty = 2) # La media es 175 grafica la línea

```

## Densidad de Probabilidad Normal



$\mu = 175$  y  $\sigma = 6$

```
pnorm(q = 180, mean = 175, sd = 6)
```

```
[1] 0.7976716
```

```

par(mfrow = c(2, 2))#ESTABLECE EL LIENZO EN EL PLOT PARA GRAFICAR
#VARIAS EN UN MISMO ESPACIO
plot(x, y, type = "l",
     xlab = "",
     ylab = "")
#AGREGA LEYENDAS AL GRÁFICO
title(main = "Densidad de Probabilidad Normal",
      sub = expression(paste(mu == 175,
                             " y ",
                             sigma == 6)))

```

```

polygon(c(min(x),
          x[x<=180],
          180),
        c(0, y[x<=180], 0),
        col="blue")#GRAFICA DENTRO DE LA DISTRIBUCIÓN
#LA PROBABILIDAD DE QUE X TOME VALORES MENORES A 180

```

*#para obtener la probabilidad de que  $x$   $P(x \leq 165)$ , es decir, la probabilidad de que  $X$  tome un valor menor o igual a 165, ejecutamos:*

```
pnorm(q = 165, mean = 175, sd = 6)
```

```
[1] 0.04779035
```

```

plot(x,y,type="l",
     xlab = "",
     ylab = "")
title(main = "Densidad de probabilidad normal",
      sub = expression(paste(mu==175,"y",sigma==6)))
polygon(c(min(x),
          x[x<=165],165),
        c(0,
          y[x<=165],0),
        col = "black")

```

*#para obtener la probabilidad de que  $x$   $P(x \leq 165)$ , es decir, la probabilidad de que  $X$  tome un valor menor o igual a 165, ejecutamos:*

```
pnorm(q = 165, mean = 175, sd = 6)
```


```
[1] 0.04779035
```

```

plot(x,y,type="l",
     xlab = "",
     ylab = "")
title(main = "Densidad de probabilidad normal",
      sub = expression(paste(mu==175,"y",sigma==6)))
polygon(c(min(x),
          x[x<=165],165),
        c(0,
          y[x<=165],0),
        col = "black")


```

### Densidad de Probabilidad Normal




$$\mu = 175 \text{ y } \sigma = 6$$

### Densidad de probabilidad normal



$$\mu = 175 \text{ y } \sigma = 6$$

### Densidad de probabilidad normal



$$\mu = 175 \text{ y } \sigma = 6$$

Para obtener la probabilidad de que  $P(165 \leq X \leq 180)$  ejecutamos el siguiente comando:


*#PARA OBTENER  $P(165 \leq X \leq 180)$ , es decir, la probabilidad de que  $X$   
#tome un valor mayor o igual a 165 y menor o igual a 180, debemos correr*

```
pnorm(q = 180, mean = 175, sd = 6) - pnorm(q = 165, mean = 175, sd = 6)
```

```
[1] 0.7498813
```

```
plot(x,y,type="l",
     xlab = "",
     ylab = "")
title(main = "Densidad de probabilidad normal",
      sub = expression(paste(mu==175,"y",sigma==6)))
polygon(c(165,
          x[x>=165&x<=180],180),
        c(0,
          y[x>=165&x<=180],0),
        col = "yellow")
```

## Densidad de probabilidad normal



$$\mu = 175 \text{ y } \sigma = 6$$

Para obtener  $P(X \geq 182)$ , es decir, la probabilidad de que  $X$  tome un valor mayor o igual a 182, una alternativa es:


```
pnorm(q = 182, mean = 175, sd = 6, lower.tail = FALSE)
```

```
[1] 0.1216725
```

```
#graficando
plot(x,y,type="l",
     xlab = "",
     ylab = "")
title(main = "Densidad de probabilidad normal",
      sub = expression(paste(mu==175,"y",sigma==6)))

polygon(c(182,
          x[x>=182], max(x)),
        c(0,
          y[x>=182], 0),
        col="blue")
```

## Densidad de probabilidad normal



$$\mu = 175 \text{ y } \sigma = 6$$

```
dev.off() # Para mostrar solo una gráfica
```

```
null device
      1
```

## CUANTILES

Recordemos que los cuantiles ayudan a determinar porcentajes que superan o no un determinado valor de la variable. Para encontrar el número  $b$ , tal que  $P(X \leq b) = 0.75$ , es decir, el cuantil de orden 0.75, ejecutamos:

```
(b <- qnorm(p = 0.75, mean = 175, sd = 6))
```

```
[1] 179.0469
```

```
#COMPROBANDO DE FORMA COMUN
pnorm(b, 175, 6)
```

```
[1] 0.75
```


```
# El cuantil se encuentra en el eje de medición (eje horizontal)
plot(x, y,
     type = "l",
```

```

xlab="",
ylab="")
title(main = "Densidad de Probabilidad Normal",
      sub = expression(paste(mu == 175, " y ", sigma == 6)))
#COLOCA UNA LÍNEA DONDE SE ENCUENTRA EL CUANTIL
axis(side = 1, at = b, font = 2, padj = 1, lwd = 2)

```

## Densidad de Probabilidad Normal



$\mu = 175$  y  $\sigma = 6$

```

# SIDE un entero que especifica donde se colocará la línea
#1 abajo 2 izquierda 3 arriba 4 derecha
#AT es donde se colocará la línea
#padj ajusta a cada línea, 0 es arriba o derecha, 1 es izq o inferior

```

## MUESTRAS ALEATORIAS

Para generar una muestra aleatoria de tamaño  $n = 1000$  de la v.a.  $X$  corremos la siguiente instrucción

```

set.seed(7563) # Para poder reproducir la muestra en el futuro
muestra <- rnorm(n = 1000, mean = 175, sd = 6)
length(muestra); mdf <- as.data.frame(muestra)

```

```
[1] 1000
```

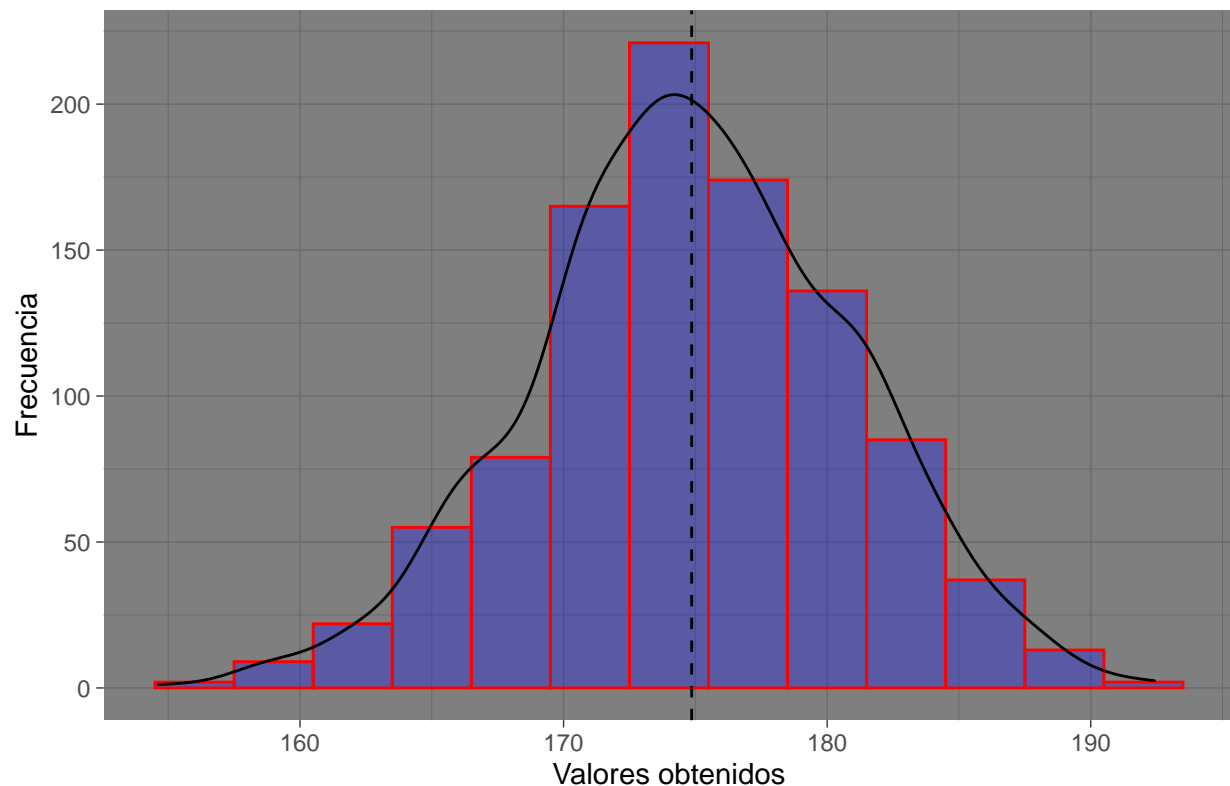
```
tail(mdf)
```

```
      muestra
995 164.7160
996 177.3317
997 156.9474
998 177.1626
999 171.3045
1000 172.4188
```

Observamos que el histograma de la muestra generada tiene forma de campana similar a la densidad de una normal

```
ggplot(mdf, aes(muestra)) +
  geom_histogram(colour = 'red',
                 fill = 'blue',
                 alpha = 0.3, # Intensidad del color fill
                 binwidth = 3) +
  geom_density(aes(y = 3*..count..)) +
  geom_vline(xintercept = mean(mdf$muestra), linetype="dashed", color = "black") +
  ggtitle('Histograma para la muestra normal') +
  labs(x = 'Valores obtenidos', y = 'Frecuencia') +
  theme_dark() +
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

## Histograma para la muestra normal



## REGLA EMPÍRICA

La regla empírica es una abreviatura utilizada para recordar el porcentaje de valores que se encuentran dentro de una banda alrededor de la media en una distribución normal con un ancho de dos, cuatro y seis veces la desviación típica, respectivamente.


```
mean <- 175; sd <- 6
x <- seq(mean-4*sd, mean+4*sd, 0.01)
y <- dnorm(x, mean, sd)
plot(x, y, type = "l",
     xlab="valores",
     ylab = "",
     xaxt = "n",
     yaxt = "n")
title(main = "Densidad de Probabilidad Normal",
     sub = expression(paste("Regla Empírica con ",
                             mu == 175,
                             " y ",
                             sigma == 6)))

abline(v=mean, lty = 2, lwd = 2)
for(k in c(-3, -2, -1, 1, 2, 3)) abline(v = mean+k*sd, lty = 2, col = abs(k))
ps <- c(mean - 3*sd, mean - 2*sd,
        mean - sd, mean,
        mean + sd,
        mean + 2*sd,
        mean + 3*sd)
axis(side = 1, at = ps)
x0 <- NULL
for(i in 1:length(ps)-1) x0 <- c(x0, (ps[i]+ps[i+1])/2)
y0 <- dnorm(x0, mean, sd)*1/3
text(x = x0, y = y0, labels = c("2.35%", "13.5%", "34%", "34%", "13.5%", "2.35%"))
x1 <- (x[1]+ps[1])/2; y1 <- dnorm(mean, mean, sd)*1/2
xf <- (x[length(x)]+ps[length(ps)])/2; yf <- dnorm(mean, mean, sd)*1/2
text(x = c(x1, xf), y = c(y1, yf), labels = c("0.15%", "0.15%"))
segments(x0 = x1, y0 = 0, x1 = x1, y1 = y1,
         col = "cornflowerblue",
         lwd = 5,
         lty = "dotted")
segments(x0 = xf, y0 = 0, x1 = xf, y1 = yf,
         col = "cornflowerblue",
         lwd = 5,
         lty = "dotted")
```

*# Draw one line as in Example 1*  
*# Color of line*  
*# Thickness of line*



## Densidad de Probabilidad Normal



## DISTRIBUCIÓN t DE STUDENT


En R para calcular valores de las funciones de densidad, distribución o cuantiles de la distribución t de Student (continua), usamos las funciones `dt`, `pt` y `qt` respectivamente. Para generar muestras aleatorias de esta distribución utilizamos la función `rt`.

Consideremos una variable aleatoria (v.a.)  $T$  que se distribuye como t de Student con 7 grados de libertad (gl) (parámetro  $gl = 7$ )

### FUNCIÓN DE DENSIDAD

```
x <- seq(-4, 4, 0.01) # Algunos valores que puede tomar la v.a.
# T con 7 gl
y <- dt(x, df = 7) # Valores correspondientes de
# la densidad t de Student con 7 gl
plot(x, y, type = "l", main = "Densidad t de Student, gl = 7", xlab="", ylab="")
abline(v = 0, lwd=2, lty=2)
```

## Densidad t de Student, gl = 7




Para encontrar  $P(T \leq 1.5)$ , ejecutamos la siguiente instrucción

```
pt(q = 1.5, df = 7)
```

```
[1] 0.9113508
```

Observemos la región que corresponde a esta probabilidad en la siguiente gráfica

```
plot(x, y,  
     type = "l",  
     main = "Densidad t de Student, gl = 7",  
     xlab="",  
     ylab="")  
polygon(c(min(x), x[x<=1.5], 1.5),  
        c(0, y[x<=1.5], 0),  
        col="purple")
```




Para encontrar  $P(T \geq 2)$ , ejecutamos

```
pt(q = 2, df = 7, lower.tail = FALSE)
```

```
[1] 0.04280966
```

Observemos la región que corresponde a esta probabilidad en la siguiente gráfica

```
plot(x, y, type = "l",  
     main = "Densidad t de Student, gl = 7",  
     xlab="", ylab="")  
polygon(c(2, x[x>=2], max(x)),  
       c(0, y[x>=2], 0),  
       col="orange")
```



## CUANTILES

Para encontrar el número  $d$  tal que  $P(T \leq d) = 0.025$ , es decir, el cuantil de orden 0.025, corremos la siguiente instrucción

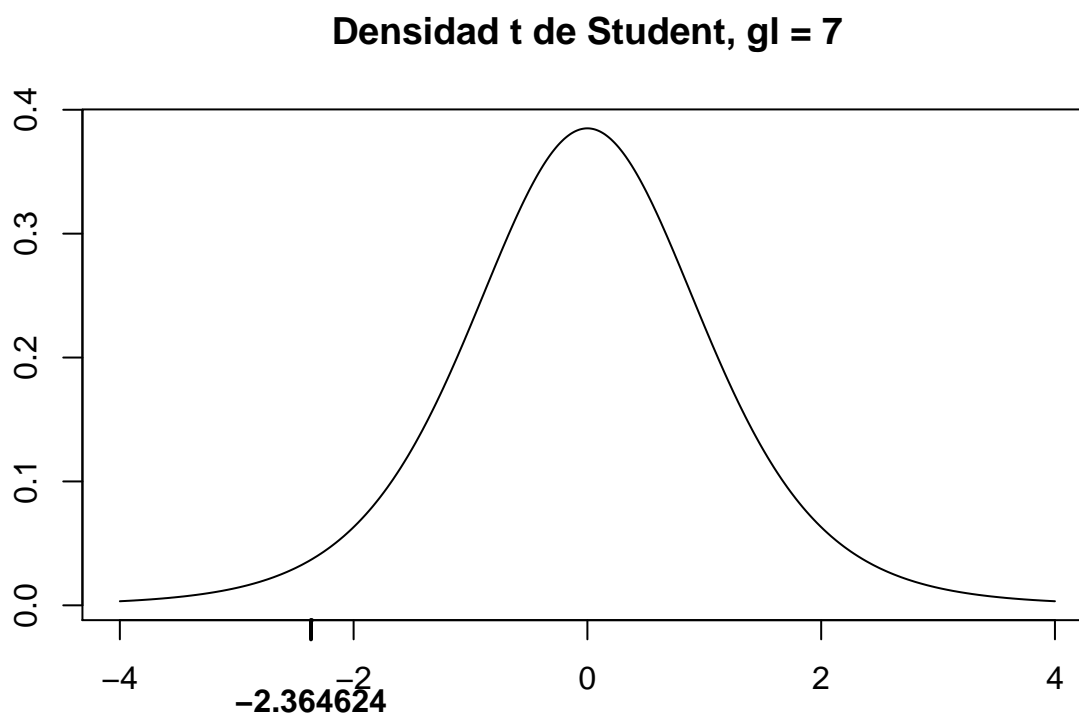
```
(d <- qt(p = 0.025, df = 7))
```

```
[1] -2.364624
```

```
#comprobando  
pt(q = d, df = 7)
```

```
[1] 0.025
```

```
# Mostramos el cuantil encontrado en el eje de medición (eje horizontal)  
plot(x, y,  
      type = "l",  
      main = "Densidad t de Student, gl = 7",  
      xlab="",  
      ylab="")  
axis(side = 1,  
      at = d,  
      font = 2,  
      padj = 1,  
      lwd = 2)
```



## MUESTRAS ALEATORIAS

Para generar una muestra aleatoria de tamaño  $n = 1000$  de la v.a.  $T$  corremos la siguiente instrucción

```
set.seed(777) # Para poder reproducir la muestra en el futuro
muestra <- rt(n = 1000, df = 7)
length(muestra); mdf <- as.data.frame(muestra)
```


```
[1] 1000
```

```
tail(mdf)
```

```
      muestra
995 0.6257672958
996 -0.2794513280
997 -0.3037697310
998 0.4514007565
999 -0.0003503659
1000 -0.1808370397
```

Observamos que el histograma de la muestra generada tiene forma de campana similar a la densidad  $t$  de Student

```
ggplot(mdf, aes(muestra)) +
  geom_histogram(colour = 'green',
                fill = 'orange',
                alpha = 0.7, # Intensidad del color fill
                binwidth = 0.5) +
  geom_density(aes(y = 0.5*..count..))+
  geom_vline(xintercept = mean(mdf$muestra), linetype="dashed", color = "black") +
  ggtitle('Histograma para la muestra t de Student') +
  labs(x = 'Valores obtenidos', y = 'Frecuencia')+
  theme_light() +
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```



## ATENUAR COLORES

Para atenuar colores es necesario utilizar  $\alpha = 0.8$  o la cantidad porcentual para atenuarse.

# RETO 1. DISTRIBUCIONES BINOMIAL, NORMAL Y T DE STUDENT

## OBJETIVO

- Calcular probabilidades y cuantiles relacionadas con algunas distribuciones de probabilidad útiles y comunes
- Generar muestras aleatorias que provengan de las distribuciones estudiadas

## REQUISITOS

- Haber trabajado con el Prewrite y el Work

## DESARROLLO

### DISTRIBUCIÓN BINOMIAL

Consideremos un experimento binomial con  $n = 35$  pruebas idénticas e independientes, en donde la probabilidad de éxito en cada prueba es  $p = 0.51$ . Encuentre lo siguiente:

1. La probabilidad de observar exactamente 10 éxitos
2. La probabilidad de observar 10 o más éxitos
3. El cuantil de orden 0.5
4. Genere una muestra aleatoria de tamaño 1000 de esta distribución, construya una tabla de frecuencias relativas con los resultados y realice el gráfico de barras de los resultados que muestre las frecuencias relativas.

### DISTRIBUCIÓN NORMAL

Considere una variable aleatoria normal con media 110 y desviación estándar 7. Realice lo siguiente:

1. Grafique la función de densidad de probabilidad
2. Encuentre la probabilidad de que la v.a. sea mayor o igual a 140
3. Encuentre el cuantil de orden 0.95
4. Genere una muestra aleatoria de tamaño 1000 y realice el histograma de frecuencias relativas para esta muestra

#### #RETO 1 SESSION 4

```
##distribucion binomial
# Consideremos un experimento binomial con $n = 35$ pruebas idénticas e
# independientes, en donde la probabilidad de éxito en cada prueba es
# $p = 0.51$. Encuentre lo siguiente:
#
# 1. La probabilidad de observar exactamente 10 éxitos
# 2. La probabilidad de observar 10 o más éxitos
# 3. El cuantil de orden 0.5
# 4. Genere una muestra aleatoria de tamaño 1000 de esta
# distribución, construya una tabla de frecuencias relativas con los
```

```
# resultados y realice el gráfico de barras de los resultados que  
# muestre las frecuencias relativas.
```

```
library(ggplot2)  
#PUNTO 1  
dbinom(x=10,size = 35,prob = 0.51)
```

```
[1] 0.003930318
```

```
#PUNTO 2  
pbinom(q=9,size = 35,prob = 0.51,  
       lower.tail = FALSE)
```

```
[1] 0.9979185
```

```
#PUNTO 3  
qbinom(p = 0.5,size = 35,prob = 0.51)
```

```
[1] 18
```

```
# PUNTO 4  
set.seed(123)  
ale1000<- rbinom(n = 1000,size = 35,prob = 0.51)  
class(ale1000)
```

```
[1] "integer"
```

```
ale1000dataaframe<-as.data.frame(table(ale1000)/length(ale1000))  
head(ale1000dataaframe)
```


	ale1000	Freq
1	8	0.001
2	10	0.003
3	11	0.012
4	12	0.018
5	13	0.033
6	14	0.059

```
tail(ale1000dataaframe)
```

	ale1000	Freq
14	22	0.053
15	23	0.030
16	24	0.015
17	25	0.007
18	26	0.003
19	27	0.003



```
ggplot(ale1000dataaframe,
  aes(x = ale1000,y = Freq))+geom_bar(stat = "identity")
```



```
##DISTRIBUCION NORMAL
# Considere una variable aleatoria normal con media 110
#y desviación estándar 7. Realice lo siguiente:
# 1. Grafique la función de densidad de probabilidad
# 2. Encuentre la probabilidad de que la v.a. sea mayor o igual a 140
# 3. Encuentre el cuantil de orden 0.95
# 4. Genere una muestra aleatoria de tamaño 1000 y realice el histograma
# de frecuencias relativas para esta muestra
```

```
#PUNTO 1
```

```
#GENERANDO LOS VALORES ALEATORIOS
```

```
vala1<- seq(10,100,by = 0.1)
View(vala1)
vala2<- dnorm(x = vala1,mean = 110,sd = 7)
class(vala1)
```

```
[1] "numeric"
```

```
class(vala2)
```

```
[1] "numeric"
```

```
df<-data.frame(vala1,vals2)
class(df)
```

```
[1] "data.frame"
```

```
View(df)
grafico<-ggplot(df,aes(vala1,vals2))+geom_line()
```

```
#PUNTO 2. PROBABILIDAD DE QUE VARIABLE ALEATORIA SEA MAYOR O IGUAL A 140
#LOWR TAIL SI ES VERDADERO LA PROBABILIDAD SERÁ P(X<=x) SI ES FALSO ES P(X>x)
pnorm(q = 140,mean = 110,sd = 7,lower.tail = FALSE)
```

```
[1] 9.107649e-06
```

```
#PUNTO 3. CUARTIL DE ORDEN 0.95
qnorm(p = 0.95,mean = 110,sd = 7)
```

```
[1] 121.514
```

```
#PUNTO 4. MUESTRA ALEATORIA DE TAMAÑO 1000 Y GENERE HISTOGRAMA DE FRECUENCIAS
set.seed(123)
datara<-rnorm(n = 1000,mean = 110,sd = 7)
dataradf<-as.data.frame(x = datara)
class(dataradf)
```


```
[1] "numeric"
```

```
class(dataradf)
```

```
[1] "data.frame"
```

```
ggplot(data = dataradf,aes(dataradf))+
  geom_histogram(colour="blue",
                 fill="red",
                 alpha=0.6,
                 binwidth = 1.2)+
  geom_density(aes(y=1.2*..count..))+
  geom_vline(xintercept = mean(dataradf),
             linetype="dashed", color = "black")+
  ggtitle(label = 'Histograma para la muestra normal')+
  labs(x='Valores obtenidos',y='Frecuencia')+
  theme_dark()+
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

## Histograma para la muestra normal



## TEOREMA CENTRAL DEL LÍMITE

### OBJETIVO

- Comprender lo que afirma el teorema central del límite obteniendo muestras aleatorias de diferentes tamaños en R y observando la manera en la que se distribuyen las medias de las muestras generadas

### REQUISITOS

- Tener R y RStudio instalados
- Haber estudiado el Prework

### ##DESARROLLO

El teorema central del límite (TCL) es una teoría estadística que establece que, dada una muestra suficientemente grande de la población, la distribución de las medias muestrales seguirá una distribución normal.


Además, el TCL afirma que a medida que el tamaño de la muestra se incrementa, la media muestral se acercará a la media de la población. Por tanto, mediante el TCL podemos definir la distribución de la media muestral de una determinada población con una varianza conocida. De manera que la distribución seguirá una distribución normal si el tamaño de la muestra es lo suficientemente grande.

Cargamos el paquete ggplot2 para hacer algunas gráficas

### #TEOREMA CENTRAL DEL LIMITE

```
library(ggplot2)
# Consideremos una variable aleatoria (v.a.) X
# con distribución exponencial y parámetro lambda = 2
x <- seq(0, 5, 0.02)
plot(x, dexp(x, rate = 2), type = "l", lwd = 2, ylab = "")
title(main = "Función de Densidad Exponencial", ylab = "f(x)",
      sub = expression("Parámetro " ~ lambda == 2))
text(x = 3, y = 1.5, labels = expression(f(x) == 2*exp(-2*x) ~ " para x " >= 0))
text(x = 3, y = 1.3, labels = paste("0 en otro caso"))
text(x = 1, y = 1, labels = expression("E(X) = " ~ 1/lambda == 1/2), col = 2)
text(x = 3, y = 0.5, labels = expression("DE(X) = " ~ 1/lambda == 1/2), col = 4)
```

## Función de Densidad Exponencial



```
print("Ahora obtenemos una muestra aleatoria de tamaño n = 4 de la distribución exponencial considerada")
```

```
[1] "Ahora obtenemos una muestra aleatoria de tamaño n = 4 de la distribución exponencial considerada"
```

```
set.seed(10) # Para reproducir posteriormente la muestra
(m1.4 <- rexp(n = 4, rate = 2))
```

```
[1] 0.007478203 0.460110602 0.376079469 0.787520925
```

```
print("Obtenemos la media de la muestra generada")
```

```
[1] "Obtenemos la media de la muestra generada"
```

```
mean(m1.4)
```

```
[1] 0.4077973
```

```
print("Ahora obtenemos 5 muestras de tamaño 3")
```

```
[1] "Ahora obtenemos 5 muestras de tamaño 3"
```

```
set.seed(64) # Para reproducir las muestras en el futuro
(m5.3 <- sapply(X = rep(3, 5), FUN = rexp, 2))
```

	[,1]	[,2]	[,3]	[,4]	[,5]
[1,]	1.5874413	0.031138339	0.08650897	0.3297026	0.82773066
[2,]	0.3272063	0.120168796	0.59122902	0.1333955	0.30709894
[3,]	1.5801568	0.006056407	1.08174334	0.5965121	0.02107677

```
print("Obtenemos las medias de las 5 muestras")
```

```
[1] "Obtenemos las medias de las 5 muestras"
```

```
(media5.3 <- apply(m5.3, 2, mean))
```

```
[1] 1.16493482 0.05245451 0.58649378 0.35320341 0.38530212
```

```
print("Ahora obtenemos 1000 muestras de tamaño 7 y las 1000 medias correspondientes a las muestras")
```

```
[1] "Ahora obtenemos 1000 muestras de tamaño 7 y las 1000 medias correspondientes a las muestras"
```

```
set.seed(465) # Para reproducir las muestras en el futuro
m1000.7 <- sapply(X = rep(7, 1000), FUN = rexp, 2)
media1000.7 <- apply(m1000.7, 2, mean)
mdf <- as.data.frame(media1000.7)
tail(mdf)
```


	media1000.7
995	0.5444073
996	0.3751581
997	0.5589332
998	0.6565002
999	0.2337858
1000	0.3259742

```
print("Observamos que el histograma de las medias tiene forma de campana")
```

```
[1] "Observamos que el histograma de las medias tiene forma de campana"
```

```
ggplot(mdf, aes(media1000.7)) +  
  geom_histogram(colour = 'green',  
                 fill = 'orange',  
                 alpha = 0.7) + # Intensidad del color fill  
  geom_vline(xintercept = mean(media1000.7), linetype="dashed", color = "black") +  
  ggtitle('Histograma para las 1000 medias') +  
  labs(x = 'medias', y = 'Frecuencia') +  
  theme_bw() +  
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

‘stat\_bin()’ using ‘bins = 30’. Pick better value with ‘binwidth’.



```
mean(media1000.7); 1/2 # Media de las 1000 medias y media de
```

```
[1] 0.4969754
```

```
[1] 0.5
```

```
# la población de la cual vienen las 1000 muestras
sd(media1000.7); (1/2)/sqrt(7) # DE de las 1000 medias y DE
```

```
[1] 0.1854891
```

```
[1] 0.1889822
```

```
# de la población de la cual vienen las 1000 muestras dividida
# por la raíz del tamaño de la muestra
```

```
print("Ahora obtenemos 1000 muestras de tamaño 33 y las 1000 medias correspondientes a las muestras")
```

```
[1] "Ahora obtenemos 1000 muestras de tamaño 33 y las 1000 medias correspondientes a las muestras"
```

```
set.seed(4465) # Para reproducir las muestras en el futuro
m1000.33 <- sapply(X = rep(33, 1000), FUN = rexp, 2)
media1000.33 <- apply(m1000.33, 2, mean)
mdf <- as.data.frame(media1000.33)
tail(mdf)
```

```
      media1000.33
995      0.3818621
996      0.3609060
997      0.5153507
998      0.5261520
999      0.5053655
1000     0.4573147
```


```
print("Observamos que el histograma de las medias es más parecida todavía a una campana")
```

```
[1] "Observamos que el histograma de las medias es más parecida todavía a una campana"
```

```
ggplot(mdf, aes(media1000.33)) +
  geom_histogram(colour = 'yellow',
                 fill = 'purple',
                 alpha = 0.7) + # Intensidad del color fill
  geom_vline(xintercept = mean(media1000.33), linetype="dashed", color = "black") +
  ggtitle('Histograma para las 1000 medias') +
  labs(x = 'medias', y = 'Frecuencia')+
  theme_get() +
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

‘stat\_bin()’ using ‘bins = 30’. Pick better value with ‘binwidth’.

## Histograma para las 1000 medias



```
mean(media1000.33); 1/2 # Media de las 1000 medias y media de la
```

```
[1] 0.501952
```

```
[1] 0.5
```

```
# población de la cual vienen las 1000 muestras
sd(media1000.33); (1/2)/sqrt(33) # DE de las 1000 medias
```

```
[1] 0.08624136
```

```
[1] 0.08703883
```

```
# y DE de la población de la cual vienen las 1000 muestras dividida
# por la raíz del tamaño de la muestra
```

```
print("Ahora obtenemos 1000 muestras de tamaño 400 y las 1000 medias correspondientes a las muestras")
```

```
[1] "Ahora obtenemos 1000 muestras de tamaño 400 y las 1000 medias correspondientes a las muestras"
```

```
set.seed(543465) # Para reproducir las muestras en el futuro
m1000.400 <- sapply(X = rep(400, 1000), FUN = rexp, 2)
media1000.400 <- apply(m1000.400, 2, mean)
mdf <- as.data.frame(media1000.400)
tail(mdf)
```



```
media1000.400
995      0.4656883
996      0.4779040
997      0.4803765
998      0.4944309
999      0.4988992
1000     0.5106146
```


```
print("Observamos que el histograma de las medias es más parecida todavía a una campana")
```

```
[1] "Observamos que el histograma de las medias es más parecida todavía a una campana"
```

```
ggplot(mdf, aes(media1000.400)) +
  geom_histogram(colour = 'orange',
                fill = 'gray',
                alpha = 0.7) + # Intensidad del color fill
  geom_vline(xintercept = mean(media1000.400), linetype="dashed", color = "black") +
  ggtitle('Histograma para las 1000 medias') +
  labs(x = 'medias', y = 'Frecuencia')+
  theme_gray() +
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

‘stat\_bin()’ using ‘bins = 30’. Pick better value with ‘binwidth’.

## Histograma para las 1000 medias



```
mean(media1000.400); 1/2 # Media de las 1000 medias y media
```

```
[1] 0.5008446
```

```
[1] 0.5
```

```
# de la población de la cual vienen las 1000 muestras  
sd(media1000.400); (1/2)/sqrt(400) # DE de las 1000 medias
```

```
[1] 0.02453529
```

```
[1] 0.025
```

```
# y DE de la población de la cual vienen las 1000 muestras  
# dividida por la raíz del tamaño de la muestra
```

## EJEMPLO 3. ALGUNOS ESTIMADORES PUNTUALES INSES- GADOS COMUNES

### OBJETIVO

- Entender la idea de estimador insesgado de un parámetro

### REQUISITOS

- Tener R y RStudio instalados
- Haber leído el prework

### DESARROLLO

Un estimador insesgado es aquel cuya esperanza matemática coincide con el valor del parámetro que sea desea estimar. En caso de no coincidir se dice que el estimador tiene sesgo. La razón de buscar un estimador insesgado es que el parámetro que deseamos estimar esté bien estimado. Es decir, si queremos estimar la media de goles por partido de determinado jugador de fútbol, hemos de utilizar una fórmula que nos proporcione un valor lo más aproximado posible al valor real.

```
#EJEMPLO 3
```

```
print("vargamos el paquete ggplot2 para hacer algunas gráficas")
```

```
[1] "vargamos el paquete ggplot2 para hacer algunas gráficas"
```

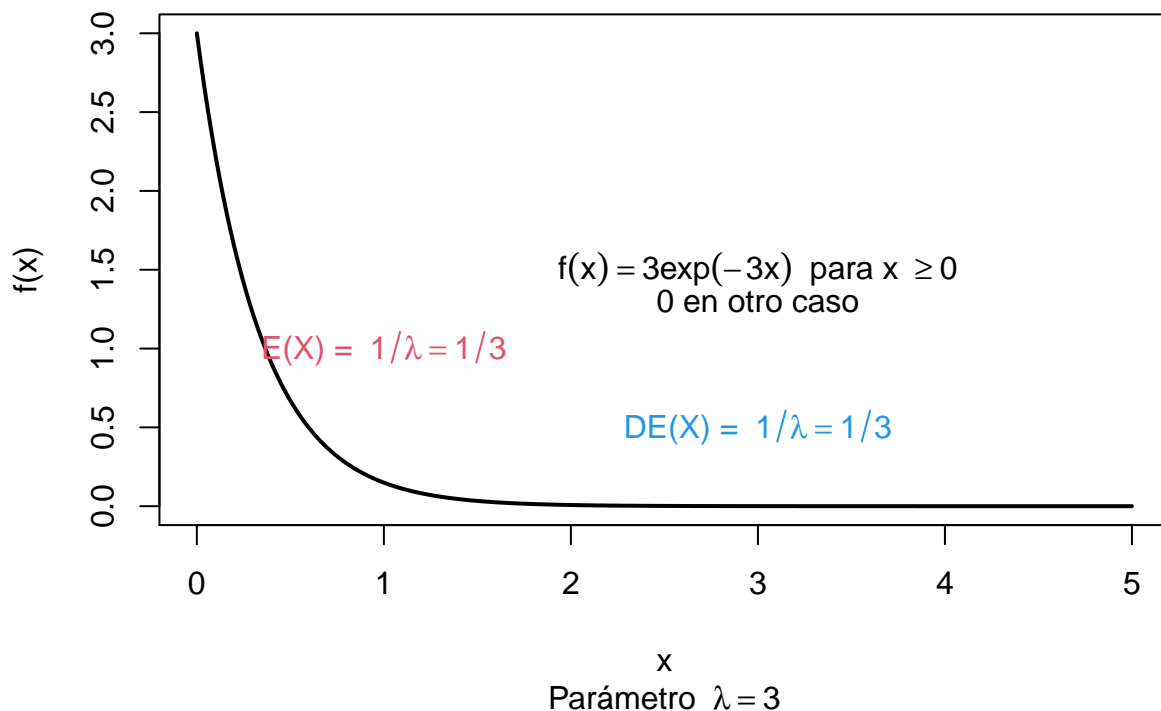
```
library(ggplot2)
```

```
print("Consideremos una variable aleatoria X con distribución exponencial y parametro lambda=3")
```

```
[1] "Consideremos una variable aleatoria X con distribución exponencial y parametro lambda=3"
```

```
x <- seq(0, 5, 0.02)
plot(x, dexp(x, rate = 3), type = "l", lwd = 2, ylab = "")
title(main = "Función de Densidad Exponencial", ylab = "f(x)",
      sub = expression("Parámetro " ~ lambda == 3))
text(x = 3, y = 1.5, labels = expression(f(x)==3*exp(-3*x) ~ " para x " >= 0))
text(x = 3, y = 1.3, labels = paste("0 en otro caso"))
text(x = 1, y = 1, labels = expression("E(X) = " ~ 1/lambda == 1/3), col = 2)
text(x = 3, y = 0.5, labels = expression("DE(X) = " ~ 1/lambda == 1/3), col = 4)
```

## Función de Densidad Exponencial



```
print("Obtenemos 1200 muestras aleatorias de tamaño 350 y las 1200 medias correspondientes a las muestras")
```

```
[1] "Obtenemos 1200 muestras aleatorias de tamaño 350 y las 1200 medias correspondientes a las muestras"
```

```
set.seed(65) # Para reproducir las muestras en el futuro
m1200.350 <- sapply(X = rep(350, 1200), FUN = rexp, rate = 3)
media1200.350 <- apply(m1200.350, 2, mean)
mdf <- as.data.frame(media1200.350)
tail(mdf)
```

```
media1200.350
1195    0.3757215
1196    0.3415659
1197    0.3043333
1198    0.3233880
```


```
1199     0.3240008
1200     0.3344396
```

```
print("Observamos que el histograma de las medias tiene forma de campana")
```

```
[1] "Observamos que el histograma de las medias tiene forma de campana"
```

```
ggplot(mdf, aes(media1200.350)) +  
  geom_histogram(colour = 'yellow',  
                 fill = 'purple',  
                 alpha = 0.7) + # Intensidad del color fill  
  geom_vline(xintercept = mean(media1200.350),  
             linetype="dashed",  
             color = "black") +  
  ggtitle('Histograma para las 1200 medias') +  
  labs(x = 'medias',  
       y = 'Frecuencia')+  
  theme_get() +  
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

‘stat\_bin()’ using ‘bins = 30’. Pick better value with ‘binwidth’.



```
mean(media1200.350); 1/3 # Media de las 1200 medias y media de
```

```
[1] 0.3337942
```

```
[1] 0.3333333
```

```
# la población de la cual provienen las 1200 muestras  
sd(media1200.350); (1/3)/sqrt(350) # DE de las 1200 medias y DE
```

```
[1] 0.01714254
```

```
[1] 0.01781742
```

```
# de la población de la cual provienen las 1200 muestras dividida  
# por la raíz del tamaño de las muestras
```

```
print("ENSAYO BERNOULLI Con las siguientes instrucciones obtenemos un solo valor, en donde el 0 (fracaso)
```

```
[1] "ENSAYO BERNOULLI Con las siguientes instrucciones obtenemos un solo valor, en donde el 0 (fracaso)
```

```
set.seed(345)  
sample(x = c(0, 1), size = 1, prob = c(0.45, 0.55))
```

```
[1] 1
```

```
rbinom(n = 1, size = 1, prob = 0.55)
```

```
[1] 1
```

```
print("Obtenemos 1000 muestras de tamaño 31 de una v.a. Bernoulli con p = 0.55")
```

```
[1] "Obtenemos 1000 muestras de tamaño 31 de una v.a. Bernoulli con p = 0.55"
```

```
set.seed(5434) # Para reproducir las muestras en el futuro  
m1000.31 <- sapply(X = rep(31, 1000), FUN = function(n) sample(x = c(0, 1), size = n, replace = TRUE, p  
media1000.31 <- apply(m1000.31, 2, mean)  
mdf <- as.data.frame(media1000.31)  
tail(mdf)
```


```
      media1000.31  
995      0.6451613  
996      0.6129032  
997      0.6774194  
998      0.5161290  
999      0.5806452  
1000     0.5161290
```

```
print("Observamos que el histograma de las medias es parecida a una campana")
```

```
[1] "Observamos que el histograma de las medias es parecida a una campana"
```

```
ggplot(mdf, aes(media1000.31)) +  
  geom_histogram(colour = 'orange',  
                 fill = 'blue',  
                 alpha = 0.7) + # Intensidad del color fill  
  geom_vline(xintercept = mean(media1000.31),  
            linetype="dashed",  
            color = "black") +  
  ggtitle('Histograma para las 1000 medias') +  
  labs(x = 'medias',  
       y = 'Frecuencia')+  
  theme_grey() +  
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

‘stat\_bin()’ using ‘bins = 30’. Pick better value with ‘binwidth’.



```
mean(media1000.31); 0.55 # Media de las 1000 medias y media de la población de la cual provienen las 10
```

```
[1] 0.5492903
```

```
[1] 0.55
```

```
sd(media1000.31); sqrt(0.55*0.45)/sqrt(31) # DE de las 1000 medias y DE
```

```
[1] 0.08767195
```

```
[1] 0.08935251
```

```
# de la población de la cual provienen las 1000 muestras dividida  
# por la raíz del tamaño de la muestra
```

```
print("Obtenemos 1150 muestras aleatorias de tamaño n1 = 54 de una distribución exponencial con parámetro")
```

```
[1] "Obtenemos 1150 muestras aleatorias de tamaño n1 = 54 de una distribución exponencial con parámetro"
```

```
set.seed(65) # Para reproducir las muestras en el futuro  
m1150.54 <- sapply(X = rep(54, 1150), FUN = rexp, rate = 3.2)  
media1150.54 <- apply(m1150.54, 2, mean)  
m1150.41 <- sapply(X = rep(41, 1150), FUN = rexp, rate = 1.5)  
media1150.41 <- apply(m1150.41, 2, mean)  
dif.medias <- media1150.54 - media1150.41 # Diferencia de medias  
dmdf <- as.data.frame(dif.medias)  
tail(dmdf)
```

```
      dif.medias  
1145 -0.3322635  
1146 -0.4433986  
1147 -0.2908058  
1148 -0.3414530  
1149 -0.1469445  
1150 -0.4128351
```


```
print("Observamos que el histograma de las diferencias de medias es parecida a una campana")
```

```
[1] "Observamos que el histograma de las diferencias de medias es parecida a una campana"
```

```
ggplot(dmdf, aes(dif.medias)) +  
  geom_histogram(colour = 'orange',  
                 fill = 'red',  
                 alpha = 0.7) + # Intensidad del color fill  
  geom_vline(xintercept = mean(dif.medias), linetype="dashed", color = "black") +  
  ggtitle('Histograma para las 1000 diferencias de medias') +  
  labs(x = 'medias', y = 'Frecuencia') +  
  theme_grey() +  
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

‘stat\_bin()’ using ‘bins = 30’. Pick better value with ‘binwidth’.

## Histograma para las 1000 diferencias de medias



```
mean(dif.medias); 1/3.2-1/1.5 # Media de las 1150 diferencias de medias y
```

```
[1] -0.3542439
```

```
[1] -0.3541667
```

```
# diferencia de medias de las poblaciones de las cuales provienen  
# las 11500 muestras  
sd(dif.medias); sqrt((1/3.2^2)/54 + (1/1.5^2)/41) # DE de las 1150
```

```
[1] 0.110714
```

```
[1] 0.1124658
```

```
# diferencias de medias y DE dada en literatura
```

```
print("Obtenemos 1100 muestras de tamaño n1 = 48 de una v.a. Bernoulli con p1 = 0.65 y otras 1100 muestr
```

```
[1] "Obtenemos 1100 muestras de tamaño n1 = 48 de una v.a. Bernoulli con p1 = 0.65 y otras 1100 muestr
```

```
set.seed(7434) # Para reproducir las muestras en el futuro
```

```
m1100.48 <- sapply(X = rep(48, 1100), FUN = function(n) sample(x = c(0, 1), size = n, replace = TRUE, p  
m1100.35 <- sapply(X = rep(35, 1100), FUN = function(n) sample(x = c(0, 1), size = n, replace = TRUE, p
```



```
media1100.48 <- apply(m1100.48, 2, mean)
media1100.35 <- apply(m1100.35, 2, mean)
dif.medias <- media1100.48 - media1100.35
dmdf <- as.data.frame(dif.medias)
tail(dmdf)
```

```
      dif.medias
1095 0.05357143
1096 0.07202381
1097 0.37321429
1098 0.20952381
1099 0.25119048
1100 0.09761905
```


```
print("Observamos que el histograma de las diferencias de medias es parecida a una campana")
```

```
[1] "Observamos que el histograma de las diferencias de medias es parecida a una campana"
```

```
ggplot(dmdf, aes(dif.medias)) +
  geom_histogram(colour = 'pink',
                 fill = 'blue',
                 alpha = 0.7) + # Intensidad del color fill
  geom_vline(xintercept = mean(dif.medias),
             linetype="dashed",
             color = "black") +
  ggtitle('Histograma para las 1100 diferencias de medias') +
  labs(x = 'medias',
       y = 'Frecuencia') +
  theme_grey() +
  theme(plot.title = element_text(hjust = 0.5, size = 16))
```

‘stat\_bin()’ using ‘bins = 30’. Pick better value with ‘binwidth’.

## Histograma para las 1100 diferencias de medias



```
mean(dif.medias); 0.65 - 0.53 # Media de las 1100
```

```
[1] 0.1196558
```

```
[1] 0.12
```

```
#diferencias de medias y diferencia de medias de las poblaciones
# de las cuales provienen las muestras
sd(dif.medias); sqrt((0.65*0.35)/48 + (0.53*0.47)/35) # DE de las 1100
```

```
[1] 0.110132
```

```
[1] 0.1088886
```

```
# diferencias de medias y DE dada en literatura
```

## RETO 2 SESION 4. ALGUNOS ESTIMADORES PUNTUALES INSESGADOS COMUNES

### OBJETIVO

- Entender la idea del estimador puntual incesgado

## REQUISITOS

- Haber estudiado el prework y el work

## DESARROLLO

1. Genere 1500 muestras de tamaño 67 de la distribución exponencial con parámetro 5
2. Obtenga las 1500 medias correspondientes a cada una de las muestras
3. Realice el histograma de frecuencias de las 1500 medias
4. Encuentre la media muestral y desviación estándar muestral de las 1500 medias
5. Compare la media muestral encontrada en el paso anterior con la media real (1/5) de la población de la cual provienen las muestras
6. Compare la desviación estándar muestral encontrada con la desviación estándar real (1/5) de la población de la cual provienen las muestras pero dividida por 67 (el tamaño de las muestras).

```
#RETO 2 SESION 4  
# 1. Genere 1500 muestras de tamaño 67 de la distribución exponencial con  
# parámetro 5  
# 2. Obtenga las 1500 medias correspondientes a cada una de las muestras  
# 3. Realice el histograma de frecuencias de las 1500 medias  
# 4. Encuentre la media muestral y desviación estándar muestral de las  
# 1500 medias  
# 5. Compare la media muestral encontrada en el paso anterior con  
# la media real (1/5) de la población de la cual provienen las muestras  
# 6. Compare la desviación estándar muestral encontrada con la desviación  
# estándar real (1/5) de la población de la cual provienen las muestras  
# pero dividida por 67 (el tamaño de las muestras)
```

```
library(ggplot2)  
set.seed(123)#PARA QUE TODO EL TEAM GENERE LOS MISMOS VALORES  
#PUNTO1  
d1 <- sample(X = rep(67, 1500), FUN = rexp, rate = 5)  
class(d1)
```

```
[1] "matrix" "array"
```

```
#PUNTO 2  
medd1<-apply(d1,2,mean)  
#SE HACE LA CONVERSION A DATA FRAME  
dfmedd1<-as.data.frame(medd1)  
class(dfmedd1)
```

```
[1] "data.frame"
```

```
#PUNTO 3 HISTOGRAMA  
graficop3<-ggplot(dfmedd1,aes(medd1))+  
  geom_histogram(colour='blue',  
                 fill='red',  
                 alpha=0.5)+  
  geom_vline(xintercept=mean(medd1),  
             linetype="dashed",  
             color="black")+  
  theme_minimal()
```

```
ggtitle("Histograma 1500 medias")+
labs(x="Media",y="Frecuencia")+
theme(plot.title = element_text(hjust = 0.5, size = 16))
```

```
#PUNTO 4
mean(medd1)
```

```
[1] 0.1995011
```

```
sd(medd1)
```

```
[1] 0.02395705
```

```
#PUNTO 5
mean(medd1); 1/5
```

```
[1] 0.1995011
```

```
[1] 0.2
```

```
#PUNTO 6
sd(medd1); (1/5)/sqrt(67)
```

```
[1] 0.02395705
```

```
[1] 0.02443389
```

## EJEMPLO 4. CONTRASTE DE HIPOTESIS

### OBJETIVO

Llevar a cabo contrastes de hipotesis que ayuden a tomar decisiones

### DESARROLLO

Un contraste de hipótesis es un procedimiento para juzgar si una propiedad que se supone en una población estadística es compatible con lo observado en una muestra de dicha población. Fue iniciada por Ronald Fisher y fundamentada posteriormente por Jerzy Neyman y Karl Pearson.

```
# EJEMPLO 4. Contraste de hipótesis

# Contrastes comunes con muestras grandes
# Contraste de cola superior
# Dada una muestra aleatoria de tamaño  $n = 40$ 

set.seed(104)
muestra <- rexp(n = 40, rate = 6) # media = 1/6 aprox 0.1667
# (media de la población)
tail(as.data.frame(muestra))
```

```

      muestra
35 0.125213495
36 0.166680130
37 0.128717925
38 0.003860131
39 0.045212421
40 0.086816614

```

```

# estamos interesados en contrastar las hipótesis  $H_0: \mu = 0.1$  vs
#  $H_1: \mu > 0.1$  (contraste de cola superior)

```

```

# El valor observado del estadístico de prueba en este caso está dado por

```

```

z0 <- (mean(muestra)-0.1)/(sd(muestra)/sqrt(40))
z0

```

```

[1] 3.41015

```

```

# que proviene de una distribución normal estándar aproximadamente.

```

```

# Supongamos que estamos interesados en encontrar la región de
# rechazo (de cola superior) con un nivel de significancia  $\alpha = 0.05$ ,
# debemos encontrar el valor  $z_{\{0.05\}}$  que satisface  $P(Z > z_{\{0.05\}}) = 0.05$ .

```

```

(z.05 <- qnorm(p = 0.05, lower.tail = FALSE))

```

```

[1] 1.644854

```

```

# Como

```

```

z0 > z.05

```

```

[1] TRUE

```

```

# rechazamos la hipótesis nula

```

```

# p-value El p-value lo podemos calcular como

```

```

(pvalue <- pnorm(z0, lower.tail = FALSE))

```

```

[1] 0.0003246356

```


```

x <- seq(-4, 4, 0.01)
y <- dnorm(x)
plot(x, y, type = "l", xlab="", ylab="")
title(main = "Densidad normal estándar",
      sub = expression(paste(mu == 0, " y ", sigma == 1)))

polygon(c(z0, x[x>=z0], max(x)), c(0, y[x>=z0], 0), col="red")
axis(side = 1,
     at = z0,
     font = 2,
     padj = 1,
     lwd = 2)

```

## Densidad normal estándar



$\mu=0$  y  $\sigma=1$

```
# Contraste de cola inferior
# Dada una muestra aleatoria de tamaño  $n = 45$ 

set.seed(174)
muestra <- sample(x = c(1, 0),
                  size = 45,
                  replace = TRUE,
                  prob = c(0.67, 0.33)); 0.67 # media real de la población
```

```
[1] 0.67
```

```
tail(as.data.frame(muestra))
```

	muestra
40	1
41	1
42	0
43	1
44	1
45	0

```
# estamos interesados en contrastar las hipótesis
#  $H_0: p = 0.9$  vs  $H_1: p < 0.9$  (contraste de cola inferior)
```

```
# El valor observado del estadístico de prueba en este caso está dado por
```

```
z0 <- (mean(muestra)-0.9)/sqrt((0.9*(1-0.9))/45)
z0
```

```
[1] -7.205108
```

```
# que proviene de una distribución normal estándar aproximadamente.
```

```
# Supongamos que estamos interesados en encontrar la  
# región de rechazo (de cola inferior) con un nivel de  
# significancia alpha = 0.05, debemos encontrar el valor  
# z_{0.05} que satisface P(Z < z_{0.05}) = 0.05.
```

```
(z.05 <- qnorm(p = 0.05))
```

```
[1] -1.644854
```

```
# Como
```

```
z0 < z.05
```

```
[1] TRUE
```

```
# rechazamos la hipótesis nula.
```

```
# p-value El p-value lo podemos calcular como
```

```
(pvalue <- pnorm(z0)) # p-value muy pequeño
```

```
[1] 2.899895e-13
```

```
# Contraste de dos colas
```

```
# Dada dos muestras aleatorias de tamaños n1 = 56 y n2 = 63
```

```
set.seed(174376)
```

```
m1 <- rexp(n = 56, rate = 4.1); 1/4.1 # media real de la población
```

```
[1] 0.2439024
```

```
tail(as.data.frame(m1))
```

```
      m1  
51 0.141795401  
52 0.159477276  
53 0.191133777  
54 0.004537536  
55 0.287620197  
56 0.100260806
```

```
m2 <- rexp(n = 63, rate = 3.4); 1/3.4 # media real de la población
```

```
[1] 0.2941176
```

```
tail(as.data.frame(m2))
```

```
      m2  
58 0.23177951  
59 0.05689371  
60 0.24539693  
61 0.15520638  
62 0.44972595  
63 0.30483678
```

```
1/4.1-1/3.4 # diferencia de medias real
```

```
[1] -0.05021521
```

```
# estamos interesados en contrastar las  
# hipótesis  $H_0: \mu_1 - \mu_2 = 0$  vs  $H_1: \mu_1 - \mu_2$  diferente de 0  
# (contraste de dos colas)  
  
# El valor observado del estadístico de prueba en este caso está dado por
```

```
z0 <- (mean(m1)-mean(m2)-0)/sqrt(var(m1)/56 + var(m2)/63)  
z0
```

```
[1] 0.6932319
```

```
# que proviene de una distribución normal estándar aproximadamente.  
  
# Supongamos que estamos interesados en encontrar la  
# región de rechazo (de dos colas) con un nivel de  
# significancia  $\alpha = 0.05$ , debemos encontrar el valor  
#  $z_{\{0.025\}}$  que satisface  $P(Z > z_{\{0.025\}}) = 0.025$ .
```

```
(z.025 <- qnorm(p = 0.025, lower.tail = FALSE))
```

```
[1] 1.959964
```

```
# Como
```

```
(z0 < -z.025) | (z0 > z.025)
```

```
[1] FALSE
```

```
# fallamos en rechazar la hipótesis nula.  
  
# p-value El p-value lo podemos calcular como  
  
(pvalue <- 2*pnorm(z0, lower.tail = FALSE))
```

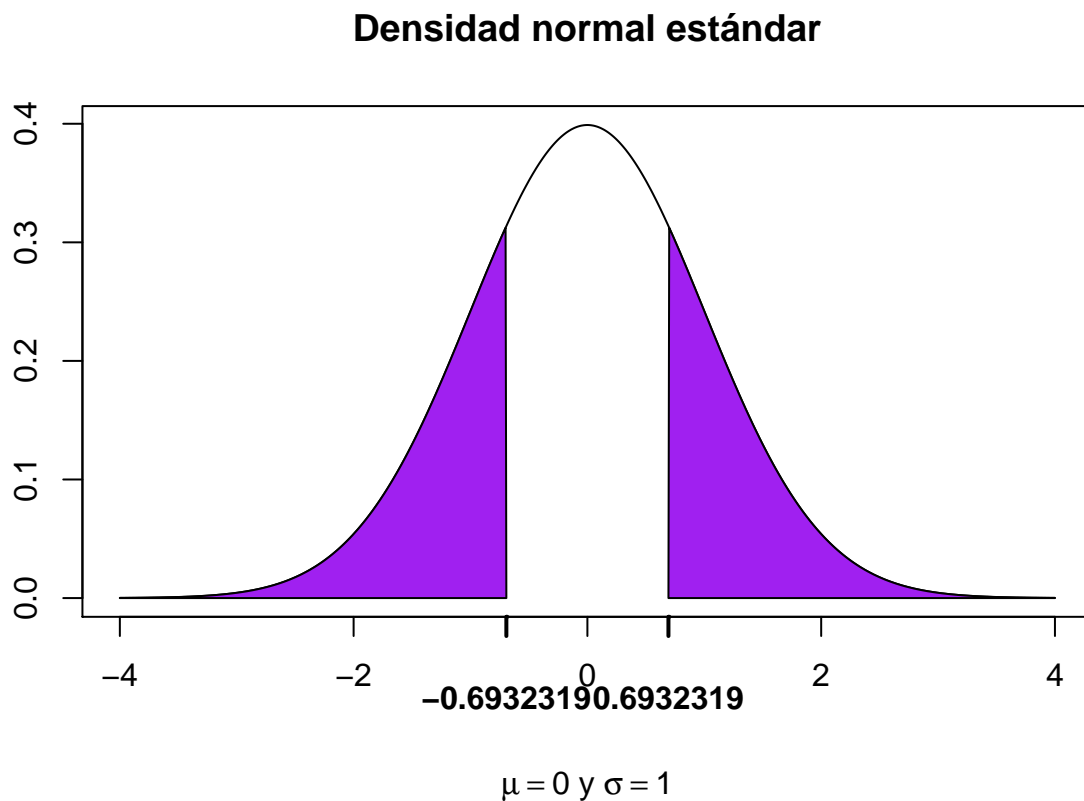


```
[1] 0.488164
```

```
x <- seq(-4, 4, 0.01)
y <- dnorm(x)
plot(x, y, type = "l", xlab="", ylab="")
title(main = "Densidad normal estándar",
      sub = expression(paste(mu == 0, " y ", sigma == 1)))

polygon(c(min(x), x[x<=-z0], -z0), c(0, y[x<=-z0], 0), col="purple")
axis(side = 1, at = -z0, font = 2, padj = 1, lwd = 2)

polygon(c(z0, x[x>=z0], max(x)), c(0, y[x>=z0], 0), col="purple")
axis(side = 1, at = z0, font = 2, padj = 1, lwd = 2)
```



```
# Contraste de hipótesis con muestras pequeñas para  $\mu$  y  $\mu_1 - \mu_2$ 
# Contraste de cola superior
# Dada una muestra aleatoria de tamaño  $n = 15$ 

set.seed(124)
muestra <- rnorm(n = 15, mean = 175, sd = 6)
tail(as.data.frame(muestra))
```

```
      muestra
10 182.2429
11 176.9100
```

```
12 166.4572
13 172.5695
14 180.9723
15 180.7529
```

```
# estamos interesados en contrastar las
# hipótesis H0:  $\mu = 170$  vs H1:  $\mu > 170$  (contraste de cola superior)

# El valor observado del estadístico de prueba en este caso está dado por

t0 <- (mean(muestra)-170)/(sd(muestra)/sqrt(15))
t0
```

```
[1] 4.410437
```

```
# que proviene de una distribución t de Student
# con n-1 = 14 grados de libertad (gl).

# Supongamos que estamos interesados en encontrar
# la región de rechazo (de cola superior) con un nivel
# de significancia  $\alpha = 0.05$ , debemos
# encontrar el valor  $t_{\{0.05\}}$  que satisface
#  $\$P(T > t_{\{0.05\}}) = 0.05$ , donde  $\$T$  se distribuye
# como t de Student con n-1 = 14 gl.

(t.05 <- qt(p = 0.05, df = 14, lower.tail = FALSE))
```

```
[1] 1.76131
```

```
# Como

t0 > t.05
```

```
[1] TRUE
```

```
# rechazamos la hipótesis nula

# p-value El p-value lo podemos calcular como


(pvalue <- pt(t0, df = 14, lower.tail = FALSE))
```

```
[1] 0.000296395
```

```
x <- seq(-5, 5, 0.01)
y <- dt(x, df = 14)
plot(x, y, type = "l", xlab="", ylab="")
title(main = "Densidad t de Student, 14 gl")

polygon(c(t0, x[x]>=t0], max(x)), c(0, y[x]>=t0], 0), col="red")
axis(side = 1, at = t0, font = 2, padj = 1, lwd = 2)
```

## Densidad t de Student, 14 gl



```
t.test(x = muestra,  
       alternative = "greater",  
       mu = 170)
```

One Sample t-test

```
data: muestra  
t = 4.4104, df = 14, p-value = 0.0002964  
alternative hypothesis: true mean is greater than 170  
95 percent confidence interval:  
 173.6258      Inf  
sample estimates:  
mean of x  
 176.0365
```

```
# Contraste de dos colas  
# Dada dos muestras aleatorias de tamaños n1 = 23 y n2 = 20  
  
set.seed(1776)  
m1 <- rnorm(n = 23, mean = 175, sd = 3)  
tail(as.data.frame(m1))
```

```
      m1  
18 173.9126
```

```
19 175.7334
20 171.3733
21 170.9339
22 178.3138
23 172.2944
```

```
m2 <- rnorm(n = 20, mean = 160, sd = 3)
tail(as.data.frame(m2))
```

```
      m2
15 164.4266
16 158.2315
17 166.0989
18 162.0823
19 161.2146
20 161.9395
```

```
175-160 # diferencia de medias real
```

```
[1] 15
```

```
# estamos interesados en contrastar las
# hipótesis  $H_0: \mu_1 - \mu_2 = 0$  vs  $H_1: \mu_1 - \mu_2$ 
# diferente de 0 (contraste de dos colas)

# El valor observado del estadístico de prueba en este caso está dado por

t0 <- (mean(m1)-mean(m2)-0)/(sqrt((22*var(m1)+19*var(m2))/(23+20-2))*sqrt(1/23+1/20))
t0
```

```
[1] 13.44122
```

```
# que proviene de una distribución t de Student con  $23 + 20 - 2 = 41$  gl

# Supongamos que estamos interesados en encontrar
# la región de rechazo (de dos colas) con un nivel de
# significancia  $\alpha = 0.05$ , debemos encontrar el valor
#  $t_{\{0.025\}}$  que satisface  $P(T > t_{\{0.025\}}) = 0.025$ .

(t.025 <- qt(p = 0.025, df= 41, lower.tail = FALSE))
```

```
[1] 2.019541
```

```
# Como

(t0 < -t.025) | (t0 > t.025)
```

```
[1] TRUE
```

```
# rechazamos la hipótesis nula.

# p-value El p-value lo podemos calcular como

(pvalue <- 2*pt(t0, df = 41, lower.tail = FALSE))
```

```
[1] 1.28906e-16
```

```
t.test(x = m1, y = m2,
       alternative = "two.sided",
       mu = 0, paired = FALSE, var.equal = TRUE)
```

#### Two Sample t-test

```
data:  m1 and m2
t = 13.441, df = 41, p-value < 2.2e-16
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 12.00835 16.25489
sample estimates:
mean of x mean of y
 175.4867  161.3551
```

## RETO 3. CONTRASTE DE HIPOTESIS

### OBJETIVO

- Llevar a cabo un contraste de hipótesis acerca de la media de una población normal cuando el tamaño muestral es pequeño

### REQUISITOS

- Haber trabajado con el prework y el work

### DESARROLLO

Dada una muestra aleatoria de tamaño  $n = 10$  de una distribución normal

```
set.seed(124)
muestra <- rnorm(n = 10, mean = 110, sd = 7) # muestra pequeña
tail(as.data.frame(muestra))
```

```
      muestra
5  119.9788
6  115.2114
7  114.9016
8  108.3945
9  111.3797
10 118.4501
```

Estamos interesados en contrastar las hipótesis  $H_0: \mu = 120$  vs  $H_1: \mu < 120$  (contraste de cola inferior).

1. Decida si rechazar o no la hipótesis nula si el nivel de significancia es  $\alpha = 0.05$
2. Obtenga el p-value de la prueba
3. Lleve a cabo la prueba con la función *t.test*

```
#RETO 3 SESION 4
```

```
# Reto 3. Contraste de hipótesis
```

```
# Dada una muestra aleatoria de tamaño n = 10 de la distribución normal
```

```
set.seed(124)
muestra <- rnorm(n = 10, mean = 110, sd = 7)
tail(as.data.frame(muestra))
```

```
      muestra
5  119.9788
6  115.2114
7  114.9016
8  108.3945
9  111.3797
10 118.4501
```

```
# estamos interesados en contrastar las hipótesis H0:
# mu = 120 vs H1: mu < 120 (contraste de cola inferior).
```

```
# 1. Decida si rechazar o no la hipótesis nula si el
# nivel de significancia es alpha = 0.05
# 2. Obtenga el p-value de la prueba
# 3. Lleve a cabo la prueba con la función t.test
```

```
#### Contraste de cola inferior
```

```
# El valor observado del estadístico de prueba en este caso está dado por
```

```
t0 <- (mean(muestra)-120)/(sd(muestra)/sqrt(10))
t0
```

```
[1] -4.444938
```

```
# que proviene de una distribución t de Student con
# n - 1 = 9 grados de libertad (gl).
```

```
# estamos interesados en encontrar la región
# de rechazo (de cola inferior) con un nivel de
# significancia alpha = 0.05, debemos encontrar el valor
# t0.05 que satisface P(T < t0.05) = 0.05, donde T se
# distribuye como t de Student con n-1 = 9 gl.
```

```
(t.05 <- qt(p = 0.05, df = 9))
```

```
[1] -1.833113
```

```
# Como
```

```
t0 < t.05
```

```
[1] TRUE
```

```
# rechazamos la hipótesis nula
```

```
# **p-value** El p-value lo podemos calcular como
```

```
(pvalue <- pt(t0, df = 9)) # 2.
```

```
[1] 0.0008059723
```

```
t.test(x = muestra, # 3.  
       alternative = "less",  
       mu = 120)
```

One Sample t-test

```
data: muestra  
t = -4.4449, df = 9, p-value = 0.000806  
alternative hypothesis: true mean is less than 120  
95 percent confidence interval:  
   -Inf 115.0074  
sample estimates:  
mean of x  
   111.5034
```

## POSTWORK

### OBJETIVO

Investigar la dependencia o independencia de las variables aleatorias X y Y, el número de goles anotados por el equipo de casa y el número de goles anotados por el equipo visitante.

### REQUISITOS

- R, RStudio
- Haber trabajado con el Prewrite y el Work

### DESARROLLO

Ahora investigarás la dependencia o independencia del número de goles anotados por el equipo de casa y el número de goles anotados por el equipo visitante mediante un procedimiento denominado bootstrap, revisa bibliografía en internet para que tengas nociones de este desarrollo.

Ya hemos estimado las probabilidades conjuntas de que el equipo de casa anote  $X=x$  goles ( $x=0,1,\dots,8$ ), y el equipo visitante anote  $Y=y$  goles ( $y=0,1,\dots,6$ ), en un partido. Obtén una tabla de cocientes al dividir estas probabilidades conjuntas por el producto de las probabilidades marginales correspondientes.

Mediante un procedimiento de bootstrap, obtén más cocientes similares a los obtenidos en la tabla del punto anterior. Esto para tener una idea de las distribuciones de la cual vienen los cocientes en la tabla anterior. Menciona en cuáles casos le parece razonable suponer que los cocientes de la tabla en el punto 1, son iguales a 1 (en tal caso tendríamos independencia de las variables aleatorias  $X$  y  $Y$ ).

#### *#Solución del Postwork Sesión 4*

*#Lo primero que haremos es cargar los paquetes que usaremos más adelante. Usamos las funciones suppressWarnings y suppressMessages para que no se impriman mensajes ni advertencias al cargar el paquete.*

```
suppressWarnings(suppressMessages(library(dplyr)))
suppressWarnings(suppressMessages(library(reshape2)))
suppressWarnings(suppressMessages(library(ggplot2)))
```

*#Comenzamos importando los datos que se encuentran en archivos csv a R*

```
url1718 <- "https://www.football-data.co.uk/mmz4281/1718/SP1.csv"
url1819 <- "https://www.football-data.co.uk/mmz4281/1819/SP1.csv"
url1920 <- "https://www.football-data.co.uk/mmz4281/1920/SP1.csv"
```

```
d1718 <- read.csv(file = url1718) # Importación de los datos a R
d1819 <- read.csv(file = url1819)
d1920 <- read.csv(file = url1920)
```

*#Obtenemos una mejor idea de los datos que se encuentran en los data frames con las funciones str, head, View y summary*

```
str(d1718); str(d1819); str(d1920)
```

```
'data.frame':  380 obs. of  64 variables:
 $ Div      : chr  "SP1" "SP1" "SP1" "SP1" ...
 $ Date     : chr  "18/08/17" "18/08/17" "19/08/17" "19/08/17" ...
 $ HomeTeam : chr  "Leganes" "Valencia" "Celta" "Girona" ...
 $ AwayTeam : chr  "Alaves" "Las Palmas" "Sociedad" "Ath Madrid" ...
 $ FTHG     : int   1 1 2 2 1 0 2 0 1 0 ...
 $ FTAG     : int   0 0 3 2 1 0 0 3 0 1 ...
 $ FTR      : chr   "H" "H" "A" "D" ...
 $ HTHG     : int   1 1 1 2 1 0 2 0 0 0 ...
 $ HTAG     : int   0 0 1 0 1 0 0 2 0 0 ...
 $ HTR      : chr   "H" "H" "D" "H" ...
 $ HS       : int  16 22 16 13 9 12 15 12 14 10 ...
 $ AS       : int   6 5 13 9 9 8 3 16 9 13 ...
 $ HST      : int   9 6 5 6 4 2 2 6 3 4 ...
 $ AST      : int   3 4 6 3 6 2 0 8 1 6 ...
 $ HF       : int  14 25 12 15 14 16 16 16 18 16 ...
 $ AF       : int  18 13 11 15 12 15 15 12 14 15 ...
 $ HC       : int   4 5 5 6 7 7 8 4 11 3 ...
 $ AC       : int   2 2 4 0 3 6 0 4 6 7 ...
 $ HY       : int   0 3 3 2 2 1 2 5 1 2 ...
```



```

$ AY      : int  1 3 1 4 4 3 1 1 3 3 ...
$ HR      : int  0 0 0 0 1 0 0 0 0 0 ...
$ AR      : int  0 1 0 1 0 1 0 1 0 0 ...
$ B365H   : num  2.05 1.75 2.38 8 1.62 1.5 1.17 9.5 3.25 2.1 ...
$ B365D   : num  3.2 3.8 3.25 4.33 4 4 8 5.75 3.25 3.3 ...
$ B365A   : num  4.1 4.5 3.2 1.45 5.5 7.5 15 1.3 2.3 3.7 ...
$ BWH     : num  2.05 1.75 2.4 7.5 1.62 1.48 1.18 9.25 3.25 2.15 ...
$ BWD     : num  3.1 3.9 3.3 4.33 3.9 4.25 7.5 5.75 3.2 3.3 ...
$ BWA     : num  4.1 4.6 3 1.45 5.75 7 14.5 1.3 2.3 3.5 ...
$ IWH     : num  2.1 1.75 2.5 7.2 1.55 1.5 1.17 7.5 3.3 2.1 ...
$ IWD     : num  3.4 3.6 3.3 4.4 4 4.2 7.5 5.5 3.35 3.4 ...
$ IWA     : num  3.5 4.8 2.85 1.45 6.2 6.5 15 1.35 2.2 3.5 ...
$ LBH     : num  2.05 1.75 2.35 7.5 1.6 1.5 1.2 9.5 3.25 2.1 ...
$ LBD     : num  3 3.8 3.25 4 3.9 4 6.5 5.25 3.1 3.1 ...
$ LBA     : num  4.2 4.33 3 1.5 5.5 7 15 1.3 2.3 3.4 ...
$ PSH     : num  2.03 1.78 2.44 8.36 1.62 ...
$ PSD     : num  3.25 4.01 3.4 4.38 4.17 4.37 7.35 5.79 3.24 3.36 ...
$ PSA     : num  4.52 4.83 3.16 1.49 6.18 7.31 15.5 1.33 2.36 3.49 ...
$ WHH     : num  2.05 1.8 2.4 8 1.67 1.5 1.22 11 3.1 2.2 ...
$ WHD     : num  3.1 3.75 3.4 4.2 3.6 4 6 4.5 3.1 3.3 ...
$ WHA     : num  4 4.2 2.9 1.44 5.5 7 13 1.33 2.4 3.3 ...
$ VCH     : num  2.05 1.8 2.4 7.5 1.65 1.5 1.2 9.5 3.25 2.15 ...
$ VCD     : num  3.2 4 3.4 4.3 4 4.2 7 5.75 3.25 3.3 ...
$ VCA     : num  4.4 4.6 3.13 1.5 5.75 7 13 1.3 2.3 3.5 ...
$ Bb1X2   : int  35 35 35 35 35 34 35 35 34 34 ...
$ BbMxH   : num  2.12 1.83 2.5 8.36 1.69 ...
$ BbAvH   : num  2.03 1.77 2.39 7.53 1.63 1.5 1.19 9.68 3.26 2.18 ...
$ BbMxD   : num  3.4 4.04 3.5 4.4 4.17 4.4 8 5.86 3.35 3.4 ...
$ BbAvD   : num  3.15 3.86 3.32 4.17 3.93 4.17 7.11 5.44 3.17 3.26 ...
$ BbMxA   : num  4.52 4.83 3.2 1.51 6.2 7.5 17 1.35 2.4 3.7 ...
$ BbAvA   : num  4.17 4.46 3.01 1.48 5.58 ...
$ BbOU    : int  31 33 34 34 33 32 27 27 32 32 ...
$ BbMx.2.5 : num  2.84 1.69 2.03 2.2 1.81 2.01 1.44 1.5 2.42 2.25 ...
$ BbAv.2.5 : num  2.68 1.64 1.98 2.11 1.75 1.94 1.4 1.46 2.36 2.14 ...
$ BbMx.2.5.1 : num  1.53 2.4 1.9 1.8 2.14 1.96 3.1 2.95 1.63 1.76 ...
$ BbAv.2.5.1 : num  1.46 2.27 1.84 1.74 2.09 1.87 2.88 2.64 1.58 1.7 ...
$ BbAH    : int  18 16 18 16 16 17 17 16 15 17 ...
$ BbAHh   : num  -0.5 -0.75 -0.25 1.25 -1 -1 -2 1.5 0.25 -0.25 ...
$ BbMxAHH : num  2.07 2.05 2.08 1.77 2.12 1.9 2.05 2.03 1.93 1.92 ...
$ BbAvAHH : num  2.03 1.97 2.05 1.75 2.06 1.86 2 1.98 1.89 1.88 ...
$ BbMxAHA : num  1.9 1.96 1.87 2.25 1.86 2.05 1.91 1.95 2.03 2.04 ...
$ BbAvAHA : num  1.86 1.91 1.83 2.16 1.82 2.01 1.86 1.89 1.98 1.99 ...
$ PSCH    : num  1.98 1.78 2.12 6.93 1.64 1.53 1.2 12.4 3.31 2.2 ...
$ PSCD    : num  3.35 4.24 3.53 3.83 4.18 4.48 8.25 7 3.32 3.27 ...
$ PSCA    : num  4.63 4.43 3.74 1.63 5.82 6.91 15.2 1.26 2.4 3.85 ...

'data.frame':  380 obs. of  61 variables:
$ Div     : chr  "SP1" "SP1" "SP1" "SP1" ...
$ Date    : chr  "17/08/2018" "17/08/2018" "18/08/2018" "18/08/2018" ...
$ HomeTeam : chr  "Betis" "Girona" "Barcelona" "Celta" ...
$ AwayTeam : chr  "Levante" "Valladolid" "Alaves" "Espanol" ...
$ FTHG    : int  0 0 3 1 1 1 2 1 2 1 ...
$ FTAG    : int  3 0 0 1 2 2 0 4 1 1 ...
$ FTR     : chr  "A" "D" "H" "D" ...

```

```

$ HTHG      : int  0 0 0 0 1 0 1 0 1 0 ...
$ HTAG      : int  1 0 0 1 1 2 0 3 1 1 ...
$ HTR       : chr  "A" "D" "D" "A" ...
$ HS        : int  22 13 25 12 16 18 10 13 17 13 ...
$ AS        : int  6 2 3 14 8 8 4 17 12 9 ...
$ HST       : int  8 1 9 2 7 6 3 2 5 4 ...
$ AST       : int  4 1 0 5 4 6 1 8 2 3 ...
$ HF        : int  10 21 6 13 16 12 11 6 12 10 ...
$ AF        : int  10 20 13 14 10 13 27 15 13 15 ...
$ HC        : int  5 3 7 8 4 7 3 2 6 4 ...
$ AC        : int  3 2 1 7 6 0 0 6 2 10 ...
$ HY        : int  0 1 0 3 2 1 1 1 4 2 ...
$ AY        : int  2 1 2 2 3 1 7 0 5 3 ...
$ HR        : int  0 0 0 0 0 0 0 0 0 0 ...
$ AR        : int  0 0 0 0 0 0 0 0 0 0 ...
$ B365H     : num  1.66 1.75 1.11 1.85 2.04 1.66 1.2 3.25 1.75 3 ...
$ B365D     : num  4 3.6 10 3.5 3.4 3.75 7 3.6 3.3 3.2 ...
$ B365A     : num  5 5 21 4.5 3.8 5.5 13 2.14 5.5 2.5 ...
$ BWH       : num  1.7 1.75 1.11 1.91 2.05 1.7 1.18 3.5 1.78 2.85 ...
$ BWD       : num  3.7 3.5 10 3.4 3.3 3.7 7.25 3.5 3.5 3.25 ...
$ BWA       : num  5.25 5.25 20 4.25 3.9 5.25 16 2.1 5 2.55 ...
$ IWH       : num  1.75 1.8 1.12 1.9 2 1.7 1.2 3.5 1.85 2.85 ...
$ IWD       : num  3.6 3.6 9 3.5 3.4 3.75 6.5 3.4 3.5 3.2 ...
$ IWA       : num  4.9 4.5 20 4.1 3.8 5 15 2.1 4.4 2.55 ...
$ PSH       : num  1.69 1.8 1.11 1.93 2.06 1.72 1.2 3.46 1.79 3.12 ...
$ PSD       : num  4.19 3.7 11.27 3.64 3.51 ...
$ PSA       : num  5.11 4.99 25.4 4.27 3.91 ...
$ WHH       : num  1.67 1.75 1.08 1.91 2.05 1.73 1.22 3.3 1.8 3 ...
$ WHD       : num  3.9 3.6 9 3.5 3.3 3.6 6 3.7 3.4 3.2 ...
$ WHA       : num  4.75 4.6 29 4 3.6 4.75 13 2.05 4.75 2.4 ...
$ VCH       : num  1.67 1.8 1.1 1.93 2.05 1.7 1.2 3.4 1.8 3 ...
$ VCD       : num  4.2 3.7 10.5 3.5 3.5 3.8 7 3.6 3.4 3.2 ...
$ VCA       : num  5.2 4.8 34 4.4 3.9 5 13 2.1 5 2.45 ...
$ Bb1X2     : int  40 40 40 38 40 40 39 40 40 39 ...
$ BbMxH     : num  1.75 1.85 1.13 1.97 2.11 1.76 1.24 3.53 1.85 3.12 ...
$ BbAvH     : num  1.68 1.78 1.1 1.9 2.03 1.7 1.21 3.38 1.78 2.99 ...
$ BbMxD     : num  4.25 3.83 11.5 3.73 3.62 3.93 7.36 3.75 3.64 3.29 ...
$ BbAvD     : num  4 3.6 9.82 3.53 3.43 3.77 6.66 3.56 3.43 3.14 ...
$ BbMxA     : num  5.25 5.27 41 4.5 3.93 ...
$ BbAvA     : num  4.95 4.79 25.67 4.2 3.76 ...
$ BbOU      : int  38 38 32 36 37 37 33 37 36 36 ...
$ BbMx.2.5  : num  1.82 2.21 1.39 2.13 2.05 1.95 1.5 1.83 2.49 2.45 ...
$ BbAv.2.5  : num  1.76 2.13 1.34 2.06 1.99 1.88 1.45 1.76 2.35 2.33 ...
$ BbMx.2.5.1 : num  2.15 1.78 3.4 1.84 1.88 1.98 2.75 2.13 1.64 1.65 ...
$ BbAv.2.5.1 : num  2.06 1.71 3.18 1.76 1.81 1.91 2.66 2.04 1.58 1.59 ...
$ BbAH      : int  20 20 19 18 18 19 19 19 18 17 ...
$ BbAHh     : num  -0.75 -0.75 -2.5 -0.75 -0.25 -0.75 -1.75 0.25 -0.75 0.25 ...
$ BbMxAHH   : num  1.89 2.06 1.95 2.26 1.76 1.96 1.85 2.08 2.11 1.82 ...
$ BbAvAHH   : num  1.85 2.01 1.91 2.18 1.74 1.91 1.8 2.03 2.04 1.75 ...
$ BbMxAHA   : num  2.07 1.9 2 1.74 2.23 2.01 2.15 1.86 1.86 2.23 ...
$ BbAvAHA   : num  2 1.85 1.95 1.71 2.14 1.94 2.07 1.83 1.82 2.12 ...
$ PSCH      : num  1.59 1.76 1.1 2.18 2.32 1.77 1.19 4.57 1.69 3.55 ...
$ PSCD      : num  4.42 3.57 11.85 3.26 3.21 ...
$ PSCA      : num  5.89 5.62 32.17 3.85 3.53 ...

```

```

'data.frame':  380 obs. of  105 variables:
 $ Div      : chr  "SP1" "SP1" "SP1" "SP1" ...
 $ Date     : chr  "16/08/2019" "17/08/2019" "17/08/2019" "17/08/2019" ...
 $ Time     : chr  "20:00" "16:00" "18:00" "19:00" ...
 $ HomeTeam : chr  "Ath Bilbao" "Celta" "Valencia" "Mallorca" ...
 $ AwayTeam : chr  "Barcelona" "Real Madrid" "Sociedad" "Eibar" ...
 $ FTHG     : int  1 1 1 2 0 4 1 0 1 1 ...
 $ FTAG     : int  0 3 1 1 1 4 0 2 2 0 ...
 $ FTR      : chr  "H" "A" "D" "H" ...
 $ HTHG     : int  0 0 0 1 0 1 0 0 0 1 ...
 $ HTAG     : int  0 1 0 0 0 1 0 1 0 0 ...
 $ HTR      : chr  "D" "A" "D" "H" ...
 $ HS       : int  11 7 14 16 13 12 9 7 13 5 ...
 $ AS       : int  11 17 12 11 4 14 16 12 14 6 ...
 $ HST      : int  5 4 6 4 2 7 2 2 4 5 ...
 $ AST      : int  2 11 3 5 2 7 4 4 3 0 ...
 $ HF       : int  14 17 13 13 17 10 18 11 11 19 ...
 $ AF       : int  9 12 14 14 11 16 15 17 19 22 ...
 $ HC       : int  3 6 3 9 8 2 2 8 6 3 ...
 $ AC       : int  8 4 3 3 0 7 9 4 1 4 ...
 $ HY       : int  1 5 4 2 1 3 2 2 2 3 ...
 $ AY       : int  1 2 4 3 4 1 1 2 6 4 ...
 $ HR       : int  0 0 1 0 1 0 0 0 1 1 ...
 $ AR       : int  0 1 0 0 0 0 0 0 0 1 ...
 $ B365H    : num  5.25 4.75 1.66 2.8 2 1.6 2.15 3.2 1.66 1.44 ...
 $ B365D    : num  3.8 4.2 3.75 3.2 3.2 3.8 3.2 3.3 3.75 4.33 ...
 $ B365A    : num  1.65 1.65 5.5 2.6 4.2 6.5 3.6 2.3 5.5 8 ...
 $ BWH      : num  5.5 4.4 1.67 2.95 2.05 1.6 2.15 3.1 1.65 1.45 ...
 $ BWD      : num  3.8 4.2 3.75 3.1 3.25 3.8 3.3 3.4 3.75 4.33 ...
 $ BWA      : num  1.65 1.72 5.5 2.6 3.9 6.25 3.6 2.3 5.75 7.5 ...
 $ IWH      : num  5 5.3 1.67 2.9 2.05 1.63 2.2 3.1 1.63 1.45 ...
 $ IWD      : num  3.8 4.2 3.75 3.1 3.1 4 3.25 3.4 3.75 4.4 ...
 $ IWA      : num  1.7 1.6 5.3 2.6 4.05 5.5 3.4 2.3 5.7 7.2 ...
 $ PSH      : num  5.15 4.73 1.68 2.98 2.1 1.62 2.29 3.13 1.63 1.49 ...
 $ PSD      : num  3.84 4.18 3.94 3.14 3.21 3.99 3.31 3.56 3.81 4.34 ...
 $ PSA      : num  1.74 1.72 5.47 2.66 4.13 6.13 3.45 2.33 6.38 7.58 ...
 $ WHH      : num  5 5.25 1.67 2.9 2.05 1.6 2.25 3 1.62 1.47 ...
 $ WHD      : num  3.8 4.2 3.8 3.1 3.2 3.9 3.3 3.5 3.75 4.2 ...
 $ WHA      : num  1.7 1.6 5.25 2.62 4 5.8 3.3 2.3 6 8 ...
 $ VCH      : num  5 4.75 1.67 2.9 2.1 1.65 2.25 3 1.62 1.45 ...
 $ VCD      : num  3.8 4.2 3.9 3.13 3.2 4 3.3 3.5 3.8 4.2 ...
 $ VCA      : num  1.75 1.73 5.75 2.7 4.1 5.75 3.3 2.3 5.75 8 ...
 $ MaxH     : num  5.5 5.3 1.72 3.05 2.1 1.65 2.31 3.2 1.67 1.52 ...
 $ MaxD     : num  3.95 4.4 3.98 3.2 3.3 4.15 3.4 3.56 3.9 4.5 ...
 $ MaxA     : num  1.76 1.73 5.75 2.7 4.25 6.5 3.6 2.4 6.5 8.5 ...
 $ AvgH     : num  5.07 4.67 1.68 2.91 2.06 1.61 2.23 3.08 1.64 1.47 ...
 $ AvgD     : num  3.81 4.12 3.8 3.09 3.18 3.95 3.25 3.41 3.76 4.23 ...
 $ AvgA     : num  1.71 1.69 5.29 2.62 4.02 5.8 3.43 2.33 5.78 7.63 ...
 $ B365.2.5 : num  1.8 1.53 2 2.3 2.5 1.8 2.1 1.9 2.1 2.2 ...
 $ B365.2.5.1 : num  2 2.5 1.8 1.61 1.53 2 1.72 1.9 1.72 1.66 ...
 $ P.2.5    : num  1.81 1.52 2.08 2.45 2.72 1.88 2.16 1.95 2.16 2.3 ...
 $ P.2.5.1  : num  2.09 2.66 1.82 1.6 1.5 2.02 1.76 1.95 1.76 1.68 ...
 $ Max.2.5  : num  1.85 1.53 2.14 2.47 2.75 1.9 2.2 1.98 2.21 2.3 ...
 $ Max.2.5.1 : num  2.11 2.72 1.83 1.65 1.54 2.05 1.77 1.95 1.78 1.71 ...

```

```

$ Avg.2.5      : num  1.79 1.49 2.07 2.34 2.59 1.84 2.13 1.92 2.13 2.23 ...
$ Avg.2.5.1    : num  2.05 2.58 1.77 1.6 1.49 1.98 1.72 1.89 1.72 1.66 ...
$ AHh          : num  0.75 0.75 -0.75 0 -0.5 -1 -0.25 0.25 -0.75 -1 ...
$ B365AHH      : num  1.99 2.04 1.91 2.05 2.08 2.05 1.95 1.88 1.86 1.88 ...
$ B365AHA      : num  1.94 1.89 2.02 1.88 1.85 1.75 1.98 2.05 2.07 2.05 ...
$ PAHH         : num  1.98 2.01 1.91 2.07 2.1 2.11 1.96 1.9 1.84 1.88 ...
$ PAHA         : num  1.94 1.91 2.01 1.85 1.82 1.81 1.96 2.02 2.08 2.04 ...
$ MaxAHH       : num  2 2.05 1.93 2.07 2.1 2.14 1.97 1.9 1.87 1.89 ...
$ MaxAHA       : num  1.95 1.91 2.03 1.88 1.85 1.85 1.99 2.06 2.08 2.08 ...
$ AvgAHH       : num  1.96 2 1.89 2.04 2.06 2.07 1.93 1.87 1.83 1.85 ...
$ AvgAHA       : num  1.92 1.88 1.99 1.85 1.83 1.8 1.95 2.01 2.06 2.03 ...
$ B365CH       : num  5.25 5.25 1.66 2.87 1.9 1.53 2.3 3 1.8 1.5 ...
$ B365CD       : num  3.8 4.2 3.75 3.2 3.1 4 3.4 3.4 3.6 4 ...
$ B365CA       : num  1.65 1.57 5.5 2.55 5 6.5 3.2 2.4 4.75 8 ...
$ BWCH         : num  4.75 4.5 1.65 2.95 1.95 1.57 2.35 3 1.8 1.5 ...
$ BWCD         : num  3.75 4.1 3.8 3.1 3.2 3.8 3.2 3.4 3.4 3.9 ...
$ BWCA         : num  1.75 1.7 5.5 2.6 4.5 6.5 3.2 2.35 5 7.75 ...
$ IWCH         : num  5 4.6 1.67 2.9 1.9 1.55 2.35 3 1.85 1.5 ...
$ IWCD         : num  3.8 3.8 3.8 3.1 3.15 4.05 3.25 3.35 3.55 3.9 ...
$ IWCA         : num  1.7 1.75 5.3 2.6 4.85 6.3 3.15 2.35 4.4 7.6 ...
$ PSCH         : num  5.34 5.1 1.69 2.96 1.9 1.54 2.43 3.13 1.82 1.57 ...
$ PSCD         : num  3.62 4.46 3.88 3.26 3.18 4.19 3.27 3.38 3.53 3.78 ...
$ PSCA         : num  1.78 1.65 5.47 2.6 5.3 6.87 3.2 2.41 5.07 7.66 ...
$ WHCH         : num  5 5 1.65 2.9 2.05 1.62 2.25 3 1.78 1.5 ...
$ WHCD         : num  3.8 4.2 3.9 3.1 3.2 3.9 3.3 3.4 3.5 3.8 ...
$ WHCA         : num  1.7 1.63 5.25 2.6 4 5.8 3.3 2.35 5 8 ...
$ VCCH         : num  4.8 5.2 1.7 3 1.9 1.57 2.45 3.13 1.87 1.55 ...
$ VCCD         : num  3.8 4.4 3.9 3.13 3.2 4 3.3 3.4 3.5 3.9 ...
$ VCCA         : num  1.8 1.65 5.5 2.63 5.2 7 3.13 2.4 4.6 8 ...
$ MaxCH        : num  5.8 6 1.72 3.05 1.95 1.58 2.46 3.38 1.87 1.58 ...
$ MaxCD        : num  3.9 4.52 3.95 3.29 3.26 4.2 3.42 3.47 3.65 4.05 ...
$ MaxCA        : num  1.81 1.75 6.2 2.72 5.3 7.3 3.58 2.48 5.35 8.9 ...
$ AvgCH        : num  5.03 4.93 1.68 2.93 1.9 1.54 2.37 3.05 1.83 1.53 ...
$ AvgCD        : num  3.66 4.26 3.82 3.14 3.16 4.05 3.25 3.34 3.5 3.84 ...
$ AvgCA        : num  1.76 1.65 5.37 2.59 4.91 6.66 3.18 2.39 4.74 7.68 ...
$ B365C.2.5    : num  1.9 1.44 2 2.2 2.75 1.9 2.1 2 2 2.37 ...
$ B365C.2.5.1  : num  1.9 2.75 1.8 1.66 1.44 1.9 1.72 1.8 1.8 1.57 ...
$ PC.2.5       : num  1.98 1.49 2.06 2.2 2.84 1.95 2.18 2.04 2.03 2.43 ...
$ PC.2.5.1     : num  1.93 2.76 1.85 1.74 1.47 1.95 1.75 1.85 1.87 1.61 ...
$ MaxC.2.5     : num  1.99 1.51 2.08 2.38 2.85 1.98 2.18 2.09 2.07 2.46 ...
$ MaxC.2.5.1   : num  2.11 2.88 1.98 1.74 1.5 2.1 1.83 2.05 1.92 1.65 ...
$ AvgC.2.5     : num  1.86 1.47 2 2.24 2.69 1.9 2.1 1.97 1.99 2.36 ...
$ AvgC.2.5.1   : num  1.97 2.63 1.82 1.66 1.46 1.92 1.74 1.85 1.83 1.59 ...
$ AHCh         : num  0.75 1 -0.75 0 -0.5 -1 -0.25 0.25 -0.75 -1 ...
$ B365CAHH     : num  1.93 1.82 1.94 2.11 1.89 1.96 2.08 1.86 2.02 2.06 ...
$ B365CAHA     : num  2 1.97 1.99 1.82 2.04 1.97 1.85 2.07 1.77 1.87 ...

```

[list output truncated]

```
head(d1718); head(d1819); head(d1920)
```

	Div	Date	HomeTeam	AwayTeam	FTHG	FTAG	FTR	HTHG	HTAG	HTR	HS	AS	HST	AST
1	SP1	18/08/17	Leganes	Alaves	1	0	H	1	0	H	16	6	9	3
2	SP1	18/08/17	Valencia	Las Palmas	1	0	H	1	0	H	22	5	6	4
3	SP1	19/08/17	Celta	Sociedad	2	3	A	1	1	D	16	13	5	6

4	SP1	19/08/17	Girona	Ath Madrid	2	2	D	2	0	H	13	9	6	3
5	SP1	19/08/17	Sevilla	Espanol	1	1	D	1	1	D	9	9	4	6
6	SP1	20/08/17	Ath Bilbao	Getafe	0	0	D	0	0	D	12	8	2	2

	HF	AF	HC	AC	HY	AY	HR	AR	B365H	B365D	B365A	BWH	BWD	BWA	IWH	IWD	IWA	LBH
1	14	18	4	2	0	1	0	0	2.05	3.20	4.10	2.05	3.10	4.10	2.10	3.4	3.50	2.05
2	25	13	5	2	3	3	0	1	1.75	3.80	4.50	1.75	3.90	4.60	1.75	3.6	4.80	1.75
3	12	11	5	4	3	1	0	0	2.38	3.25	3.20	2.40	3.30	3.00	2.50	3.3	2.85	2.35
4	15	15	6	0	2	4	0	1	8.00	4.33	1.45	7.50	4.33	1.45	7.20	4.4	1.45	7.50
5	14	12	7	3	2	4	1	0	1.62	4.00	5.50	1.62	3.90	5.75	1.55	4.0	6.20	1.60
6	16	15	7	6	1	3	0	1	1.50	4.00	7.50	1.48	4.25	7.00	1.50	4.2	6.50	1.50

	LBD	LBA	PSH	PSD	PSA	WHH	WHD	WHA	VCH	VCD	VCA	Bb1X2	BbMxH	BbAvH	BbMxD
1	3.00	4.20	2.03	3.25	4.52	2.05	3.10	4.00	2.05	3.2	4.40	35	2.12	2.03	3.40
2	3.80	4.33	1.78	4.01	4.83	1.80	3.75	4.20	1.80	4.0	4.60	35	1.83	1.77	4.04
3	3.25	3.00	2.44	3.40	3.16	2.40	3.40	2.90	2.40	3.4	3.13	35	2.50	2.39	3.50
4	4.00	1.50	8.36	4.38	1.49	8.00	4.20	1.44	7.50	4.3	1.50	35	8.36	7.53	4.40
5	3.90	5.50	1.62	4.17	6.18	1.67	3.60	5.50	1.65	4.0	5.75	35	1.69	1.63	4.17
6	4.00	7.00	1.53	4.37	7.31	1.50	4.00	7.00	1.50	4.2	7.00	34	1.53	1.50	4.40

	BbAvD	BbMxA	BbAvA	BbOU	BbMx.2.5	BbAv.2.5	BbMx.2.5.1	BbAv.2.5.1	BbAH	BbAHh
1	3.15	4.52	4.17	31	2.84	2.68	1.53	1.46	18	-0.50
2	3.86	4.83	4.46	33	1.69	1.64	2.40	2.27	16	-0.75
3	3.32	3.20	3.01	34	2.03	1.98	1.90	1.84	18	-0.25
4	4.17	1.51	1.48	34	2.20	2.11	1.80	1.74	16	1.25
5	3.93	6.20	5.58	33	1.81	1.75	2.14	2.09	16	-1.00
6	4.17	7.50	6.94	32	2.01	1.94	1.96	1.87	17	-1.00

	BbMxAHH	BbAvAHH	BbMxAHA	BbAvAHA	PSCH	PSCD	PSCA
1	2.07	2.03	1.90	1.86	1.98	3.35	4.63
2	2.05	1.97	1.96	1.91	1.78	4.24	4.43
3	2.08	2.05	1.87	1.83	2.12	3.53	3.74
4	1.77	1.75	2.25	2.16	6.93	3.83	1.63
5	2.12	2.06	1.86	1.82	1.64	4.18	5.82
6	1.90	1.86	2.05	2.01	1.53	4.48	6.91

Div	Date	HomeTeam	AwayTeam	FTHG	FTAG	FTR	HTHG	HTAG	HTR	HS	AS	HST
1	SP1 17/08/2018	Betis	Levante	0	3	A	0	1	A	22	6	8
2	SP1 17/08/2018	Girona	Valladolid	0	0	D	0	0	D	13	2	1
3	SP1 18/08/2018	Barcelona	Alaves	3	0	H	0	0	D	25	3	9
4	SP1 18/08/2018	Celta	Espanol	1	1	D	0	1	A	12	14	2
5	SP1 18/08/2018	Villarreal	Sociedad	1	2	A	1	1	D	16	8	7
6	SP1 19/08/2018	Eibar	Huesca	1	2	A	0	2	A	18	8	6

	AST	HF	AF	HC	AC	HY	AY	HR	AR	B365H	B365D	B365A	BWH	BWD	BWA	IWH	IWD	IWA
1	4	10	10	5	3	0	2	0	0	1.66	4.00	5.0	1.70	3.7	5.25	1.75	3.60	4.9
2	1	21	20	3	2	1	1	0	0	1.75	3.60	5.0	1.75	3.5	5.25	1.80	3.60	4.5
3	0	6	13	7	1	0	2	0	0	1.11	10.00	21.0	1.11	10.0	20.00	1.12	9.00	20.0
4	5	13	14	8	7	3	2	0	0	1.85	3.50	4.5	1.91	3.4	4.25	1.90	3.50	4.1
5	4	16	10	4	6	2	3	0	0	2.04	3.40	3.8	2.05	3.3	3.90	2.00	3.40	3.8
6	6	12	13	7	0	1	1	0	0	1.66	3.75	5.5	1.70	3.7	5.25	1.70	3.75	5.0

	PSH	PSD	PSA	WHH	WHD	WHA	VCH	VCD	VCA	Bb1X2	BbMxH	BbAvH	BbMxD	BbAvD
1	1.69	4.19	5.11	1.67	3.9	4.75	1.67	4.2	5.2	40	1.75	1.68	4.25	4.00
2	1.80	3.70	4.99	1.75	3.6	4.60	1.80	3.7	4.8	40	1.85	1.78	3.83	3.60
3	1.11	11.27	25.40	1.08	9.0	29.00	1.10	10.5	34.0	40	1.13	1.10	11.50	9.82
4	1.93	3.64	4.27	1.91	3.5	4.00	1.93	3.5	4.4	38	1.97	1.90	3.73	3.53
5	2.06	3.51	3.91	2.05	3.3	3.60	2.05	3.5	3.9	40	2.11	2.03	3.62	3.43
6	1.72	3.90	5.26	1.73	3.6	4.75	1.70	3.8	5.0	40	1.76	1.70	3.93	3.77

	BbMxA	BbAvA	BbOU	BbMx.2.5	BbAv.2.5	BbMx.2.5.1	BbAv.2.5.1	BbAH	BbAHh	BbMxAHH
--	-------	-------	------	----------	----------	------------	------------	------	-------	---------

1	5.25	4.95	38	1.82	1.76	2.15	2.06	20	-0.75	1.89
2	5.27	4.79	38	2.21	2.13	1.78	1.71	20	-0.75	2.06
3	41.00	25.67	32	1.39	1.34	3.40	3.18	19	-2.50	1.95
4	4.50	4.20	36	2.13	2.06	1.84	1.76	18	-0.75	2.26
5	3.93	3.76	37	2.05	1.99	1.88	1.81	18	-0.25	1.76
6	5.50	5.08	37	1.95	1.88	1.98	1.91	19	-0.75	1.96

	BbAvAHH	BbMxAHA	BbAvAHA	PSCH	PSCD	PSCA
1	1.85	2.07	2.00	1.59	4.42	5.89
2	2.01	1.90	1.85	1.76	3.57	5.62
3	1.91	2.00	1.95	1.10	11.85	32.17
4	2.18	1.74	1.71	2.18	3.26	3.85
5	1.74	2.23	2.14	2.32	3.21	3.53
6	1.91	2.01	1.94	1.77	3.68	5.32

Div	Date	Time	HomeTeam	AwayTeam	FTHG	FTAG	FTR	HTHG	HTAG	HTR	HS	AS
1	SP1	16/08/2019	20:00	Ath Bilbao	Barcelona	1	0	H	0	0	D	11 11
2	SP1	17/08/2019	16:00	Celta	Real Madrid	1	3	A	0	1	A	7 17
3	SP1	17/08/2019	18:00	Valencia	Sociedad	1	1	D	0	0	D	14 12
4	SP1	17/08/2019	19:00	Mallorca	Eibar	2	1	H	1	0	H	16 11
5	SP1	17/08/2019	20:00	Leganes	Osasuna	0	1	A	0	0	D	13 4
6	SP1	17/08/2019	20:00	Villarreal	Granada	4	4	D	1	1	D	12 14

HST	AST	HF	AF	HC	AC	HY	AY	HR	AR	B365H	B365D	B365A	BWH	BWD	BWA	IWH	IWD	
1	5	2	14	9	3	8	1	1	0	0	5.25	3.80	1.65	5.50	3.80	1.65	5.00	3.80
2	4	11	17	12	6	4	5	2	0	1	4.75	4.20	1.65	4.40	4.20	1.72	5.30	4.20
3	6	3	13	14	3	3	4	4	1	0	1.66	3.75	5.50	1.67	3.75	5.50	1.67	3.75
4	4	5	13	14	9	3	2	3	0	0	2.80	3.20	2.60	2.95	3.10	2.60	2.90	3.10
5	2	2	17	11	8	0	1	4	1	0	2.00	3.20	4.20	2.05	3.25	3.90	2.05	3.10
6	7	7	10	16	2	7	3	1	0	0	1.60	3.80	6.50	1.60	3.80	6.25	1.63	4.00

IWA	PSH	PSD	PSA	WHH	WHD	WHA	VCH	VCD	VCA	MaxH	MaxD	MaxA	AvgH	AvgD	
1	1.70	5.15	3.84	1.74	5.00	3.8	1.70	5.00	3.80	1.75	5.50	3.95	1.76	5.07	3.81
2	1.60	4.73	4.18	1.72	5.25	4.2	1.60	4.75	4.20	1.73	5.30	4.40	1.73	4.67	4.12
3	5.30	1.68	3.94	5.47	1.67	3.8	5.25	1.67	3.90	5.75	1.72	3.98	5.75	1.68	3.80
4	2.60	2.98	3.14	2.66	2.90	3.1	2.62	2.90	3.13	2.70	3.05	3.20	2.70	2.91	3.09
5	4.05	2.10	3.21	4.13	2.05	3.2	4.00	2.10	3.20	4.10	2.10	3.30	4.25	2.06	3.18
6	5.50	1.62	3.99	6.13	1.60	3.9	5.80	1.65	4.00	5.75	1.65	4.15	6.50	1.61	3.95

AvgA	B365.2.5	B365.2.5.1	P.2.5	P.2.5.1	Max.2.5	Max.2.5.1	Avg.2.5	Avg.2.5.1	
1	1.71	1.80	2.00	1.81	2.09	1.85	2.11	1.79	2.05
2	1.69	1.53	2.50	1.52	2.66	1.53	2.72	1.49	2.58
3	5.29	2.00	1.80	2.08	1.82	2.14	1.83	2.07	1.77
4	2.62	2.30	1.61	2.45	1.60	2.47	1.65	2.34	1.60
5	4.02	2.50	1.53	2.72	1.50	2.75	1.54	2.59	1.49
6	5.80	1.80	2.00	1.88	2.02	1.90	2.05	1.84	1.98

AHh	B365AHH	B365AHA	PAHH	PAHA	MaxAHH	MaxAHA	AvgAHH	AvgAHA	B365CH	B365CD	
1	0.75	1.99	1.94	1.98	1.94	2.00	1.95	1.96	1.92	5.25	3.80
2	0.75	2.04	1.89	2.01	1.91	2.05	1.91	2.00	1.88	5.25	4.20
3	-0.75	1.91	2.02	1.91	2.01	1.93	2.03	1.89	1.99	1.66	3.75
4	0.00	2.05	1.88	2.07	1.85	2.07	1.88	2.04	1.85	2.87	3.20
5	-0.50	2.08	1.85	2.10	1.82	2.10	1.85	2.06	1.83	1.90	3.10
6	-1.00	2.05	1.75	2.11	1.81	2.14	1.85	2.07	1.80	1.53	4.00

B365CA	BWCH	BWCD	BWCA	IWCH	IWCD	IWCA	PSCH	PSCD	PSCA	WHCH	WHCD	WHCA	VCCH	VCCD	
1	1.65	4.75	3.75	1.75	5.00	3.80	1.70	5.34	3.62	1.78	5.00	3.8	1.70	4.80	3.80
2	1.57	4.50	4.10	1.70	4.60	3.80	1.75	5.10	4.46	1.65	5.00	4.2	1.63	5.20	4.40
3	5.50	1.65	3.80	5.50	1.67	3.80	5.30	1.69	3.88	5.47	1.65	3.9	5.25	1.70	3.90
4	2.55	2.95	3.10	2.60	2.90	3.10	2.60	2.96	3.26	2.60	2.90	3.1	2.60	3.00	3.13

5	5.00	1.95	3.20	4.50	1.90	3.15	4.85	1.90	3.18	5.30	2.05	3.2	4.00	1.90	3.20
6	6.50	1.57	3.80	6.50	1.55	4.05	6.30	1.54	4.19	6.87	1.62	3.9	5.80	1.57	4.00
VCCA MaxCH MaxCD MaxCA AvgCH AvgCD AvgCA B365C.2.5 B365C.2.5.1 PC.2.5															
1	1.80	5.80	3.90	1.81	5.03	3.66	1.76		1.90			1.90		1.98	
2	1.65	6.00	4.52	1.75	4.93	4.26	1.65		1.44			2.75		1.49	
3	5.50	1.72	3.95	6.20	1.68	3.82	5.37		2.00			1.80		2.06	
4	2.63	3.05	3.29	2.72	2.93	3.14	2.59		2.20			1.66		2.20	
5	5.20	1.95	3.26	5.30	1.90	3.16	4.91		2.75			1.44		2.84	
6	7.00	1.58	4.20	7.30	1.54	4.05	6.66		1.90			1.90		1.95	
PC.2.5.1 MaxC.2.5 MaxC.2.5.1 AvgC.2.5 AvgC.2.5.1 AHCh B365CAHH B365CAHA															
1		1.93		1.99		2.11		1.86		1.97	0.75		1.93		2.00
2		2.76		1.51		2.88		1.47		2.63	1.00		1.82		1.97
3		1.85		2.08		1.98		2.00		1.82	-0.75		1.94		1.99
4		1.74		2.38		1.74		2.24		1.66	0.00		2.11		1.82
5		1.47		2.85		1.50		2.69		1.46	-0.50		1.89		2.04
6		1.95		1.98		2.10		1.90		1.92	-1.00		1.96		1.97
PCAHH PCAHA MaxCAHH MaxCAHA AvgCAHH AvgCAHA															
1	1.91	2.01		2.02		2.03		1.91		1.98					
2	1.85	2.07		2.00		2.20		1.82		2.06					
3	1.92	2.00		1.96		2.12		1.89		2.00					
4	2.09	1.83		2.12		1.88		2.07		1.83					
5	1.90	2.01		1.95		2.06		1.90		1.99					
6	1.96	1.96		1.98		2.12		1.93		1.95					

[View\(d1718\)](#); [View\(d1819\)](#); [View\(d1920\)](#)  
[summary\(d1718\)](#); [summary\(d1819\)](#); [summary\(d1920\)](#)

Div	Date	HomeTeam	AwayTeam
Length:380	Length:380	Length:380	Length:380
Class :character	Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character	Mode :character

FTHG	FTAG	FTR	HTHG
Min. :0.000	Min. :0.000	Length:380	Min. :0.0000
1st Qu.:0.750	1st Qu.:0.000	Class :character	1st Qu.:0.0000
Median :1.000	Median :1.000	Mode :character	Median :0.0000
Mean :1.547	Mean :1.147		Mean :0.6605
3rd Qu.:2.000	3rd Qu.:2.000		3rd Qu.:1.0000
Max. :7.000	Max. :6.000		Max. :5.0000

HTAG	HTR	HS	AS
Min. :0.0000	Length:380	Min. : 2.00	Min. : 1.00
1st Qu.:0.0000	Class :character	1st Qu.:10.00	1st Qu.: 8.00
Median :0.0000	Mode :character	Median :13.00	Median :10.00
Mean :0.4868		Mean :13.53	Mean :10.47
3rd Qu.:1.0000		3rd Qu.:16.00	3rd Qu.:13.00
Max. :3.0000		Max. :30.00	Max. :24.00

HST	AST	HF	AF
Min. : 0.000	Min. : 0.000	Min. : 4.00	Min. : 0.00
1st Qu.: 3.000	1st Qu.: 2.000	1st Qu.:11.00	1st Qu.:11.00

Median : 4.500	Median : 3.000	Median :13.00	Median :14.00
Mean : 4.758	Mean : 3.805	Mean :13.73	Mean :13.95
3rd Qu.: 6.000	3rd Qu.: 5.000	3rd Qu.:17.00	3rd Qu.:17.00
Max. :14.000	Max. :13.000	Max. :29.00	Max. :29.00

HC	AC	HY	AY
Min. : 0.000	Min. : 0.000	Min. :0.000	Min. :0.000
1st Qu.: 4.000	1st Qu.: 2.000	1st Qu.:1.000	1st Qu.:2.000
Median : 5.000	Median : 4.000	Median :2.000	Median :3.000
Mean : 5.613	Mean : 4.192	Mean :2.339	Mean :2.676
3rd Qu.: 7.000	3rd Qu.: 6.000	3rd Qu.:3.000	3rd Qu.:4.000
Max. :16.000	Max. :14.000	Max. :8.000	Max. :9.000

HR	AR	B365H	B365D
Min. :0.0000	Min. :0.00000	Min. : 1.050	Min. : 2.790
1st Qu.:0.0000	1st Qu.:0.00000	1st Qu.: 1.617	1st Qu.: 3.290
Median :0.0000	Median :0.00000	Median : 2.075	Median : 3.500
Mean :0.1105	Mean :0.07895	Mean : 2.777	Mean : 4.259
3rd Qu.:0.0000	3rd Qu.:0.00000	3rd Qu.: 2.790	3rd Qu.: 4.330
Max. :2.0000	Max. :2.00000	Max. :17.000	Max. :15.000

B365A	BWH	BWD	BWA
Min. : 1.170	Min. : 1.050	Min. : 2.950	Min. : 1.180
1st Qu.: 2.600	1st Qu.: 1.650	1st Qu.: 3.300	1st Qu.: 2.600
Median : 3.700	Median : 2.100	Median : 3.600	Median : 3.700
Mean : 5.192	Mean : 2.744	Mean : 4.278	Mean : 5.204
3rd Qu.: 5.500	3rd Qu.: 2.750	3rd Qu.: 4.330	3rd Qu.: 5.500
Max. :34.000	Max. :14.500	Max. :15.500	Max. :34.000

IWH	IWD	IWA	LBH
Min. : 1.070	Min. : 3.050	Min. : 1.200	Min. : 1.050
1st Qu.: 1.650	1st Qu.: 3.300	1st Qu.: 2.600	1st Qu.: 1.610
Median : 2.100	Median : 3.500	Median : 3.500	Median : 2.050
Mean : 2.721	Mean : 4.161	Mean : 5.041	Mean : 2.742
3rd Qu.: 2.700	3rd Qu.: 4.200	3rd Qu.: 5.300	3rd Qu.: 2.750
Max. :15.000	Max. :12.000	Max. :27.000	Max. :19.000
			NA's :1

LBD	LBA	PSH	PSD
Min. : 2.900	Min. : 1.170	Min. : 1.050	Min. : 3.020
1st Qu.: 3.250	1st Qu.: 2.575	1st Qu.: 1.660	1st Qu.: 3.410
Median : 3.500	Median : 3.600	Median : 2.120	Median : 3.705
Mean : 4.152	Mean : 5.375	Mean : 2.857	Mean : 4.539
3rd Qu.: 4.200	3rd Qu.: 5.500	3rd Qu.: 2.850	3rd Qu.: 4.455
Max. :17.000	Max. :41.000	Max. :19.650	Max. :20.380
NA's :1	NA's :1		

PSA	WHH	WHD	WHA
Min. : 1.180	Min. : 1.060	Min. : 2.900	Min. : 1.170
1st Qu.: 2.670	1st Qu.: 1.665	1st Qu.: 3.250	1st Qu.: 2.600
Median : 3.845	Median : 2.100	Median : 3.500	Median : 3.550
Mean : 5.522	Mean : 2.738	Mean : 4.092	Mean : 5.041
3rd Qu.: 5.942	3rd Qu.: 2.750	3rd Qu.: 4.200	3rd Qu.: 5.500
Max. :36.500	Max. :17.000	Max. :15.000	Max. :26.000

VCH	VCD	VCA	Bb1X2
-----	-----	-----	-------



Min. : 1.040	Min. : 3.000	Min. : 1.180	Min. : 3.00
1st Qu.: 1.650	1st Qu.: 3.400	1st Qu.: 2.630	1st Qu.:35.00
Median : 2.100	Median : 3.700	Median : 3.700	Median :37.00
Mean : 2.762	Mean : 4.416	Mean : 5.472	Mean :37.71
3rd Qu.: 2.800	3rd Qu.: 4.400	3rd Qu.: 5.750	3rd Qu.:40.00
Max. :15.000	Max. :17.000	Max. :36.000	Max. :43.00

BbMxH	BbAvH	BbMxD	BbAvD
Min. : 1.080	Min. : 1.050	Min. : 3.110	Min. : 2.940
1st Qu.: 1.700	1st Qu.: 1.640	1st Qu.: 3.478	1st Qu.: 3.328
Median : 2.200	Median : 2.090	Median : 3.750	Median : 3.570
Mean : 2.966	Mean : 2.743	Mean : 4.636	Mean : 4.261
3rd Qu.: 2.882	3rd Qu.: 2.765	3rd Qu.: 4.553	3rd Qu.: 4.272
Max. :19.650	Max. :16.300	Max. :20.380	Max. :15.320

BbMxA	BbAvA	BbOU	BbMx.2.5
Min. : 1.210	Min. : 1.170	Min. : 3.00	Min. :1.130
1st Qu.: 2.728	1st Qu.: 2.607	1st Qu.:31.75	1st Qu.:1.667
Median : 3.920	Median : 3.665	Median :34.00	Median :1.960
Mean : 6.107	Mean : 5.190	Mean :34.06	Mean :1.950
3rd Qu.: 6.105	3rd Qu.: 5.543	3rd Qu.:37.00	3rd Qu.:2.203
Max. :67.000	Max. :33.420	Max. :42.00	Max. :3.080

BbAv.2.5	BbMx.2.5.1	BbAv.2.5.1	BbAH
Min. :1.120	Min. :1.470	Min. :1.410	Min. : 1.00
1st Qu.:1.617	1st Qu.:1.780	1st Qu.:1.718	1st Qu.:17.00
Median :1.880	Median :2.000	Median :1.920	Median :18.00
Mean :1.872	Mean :2.284	Mean :2.162	Mean :18.16
3rd Qu.:2.120	3rd Qu.:2.402	3rd Qu.:2.283	3rd Qu.:19.00
Max. :2.850	Max. :7.000	Max. :5.970	Max. :24.00

BbAHh	BbMxAHH	BbAvAHH	BbMxAHA
Min. :-3.2500	Min. :1.610	Min. :1.580	Min. :1.680
1st Qu.: -0.7500	1st Qu.:1.890	1st Qu.:1.840	1st Qu.:1.897
Median : -0.2500	Median :1.985	Median :1.930	Median :1.970
Mean : -0.4059	Mean :1.988	Mean :1.938	Mean :1.988
3rd Qu.: 0.0625	3rd Qu.:2.070	3rd Qu.:2.020	3rd Qu.:2.080
Max. : 2.0000	Max. :2.420	Max. :2.340	Max. :2.520

BbAvAHA	PSCH	PSCD	PSCA
Min. :1.630	Min. : 1.060	Min. : 2.930	Min. : 1.160
1st Qu.:1.850	1st Qu.: 1.640	1st Qu.: 3.410	1st Qu.: 2.590
Median :1.930	Median : 2.120	Median : 3.700	Median : 3.850
Mean :1.937	Mean : 2.839	Mean : 4.508	Mean : 5.695
3rd Qu.:2.030	3rd Qu.: 2.980	3rd Qu.: 4.560	3rd Qu.: 6.095
Max. :2.440	Max. :18.700	Max. :18.500	Max. :46.000
	NA's :1	NA's :1	NA's :1

Div	Date	HomeTeam	AwayTeam
Length:380	Length:380	Length:380	Length:380
Class :character	Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character	Mode :character

FTHG	FTAG	FTR	HTHG
Min. :0.000	Min. :0.000	Length:380	Min. :0.0000
1st Qu.:1.000	1st Qu.:0.000	Class :character	1st Qu.:0.0000
Median :1.000	Median :1.000	Mode :character	Median :0.0000
Mean :1.453	Mean :1.134		Mean :0.5447
3rd Qu.:2.000	3rd Qu.:2.000		3rd Qu.:1.0000
Max. :8.000	Max. :6.000		Max. :3.0000
HTAG	HTR	HS	AS
Min. :0.0000	Length:380	Min. : 3.00	Min. : 2.00
1st Qu.:0.0000	Class :character	1st Qu.:10.00	1st Qu.: 8.00
Median :0.0000	Mode :character	Median :13.00	Median :10.00
Mean :0.5132		Mean :13.87	Mean :10.43
3rd Qu.:1.0000		3rd Qu.:17.00	3rd Qu.:13.00
Max. :5.0000		Max. :34.00	Max. :21.00
HST	AST	HF	AF
Min. : 0.000	Min. : 0.000	Min. : 1.00	Min. : 3.00
1st Qu.: 3.000	1st Qu.: 2.000	1st Qu.:11.00	1st Qu.:11.00
Median : 5.000	Median : 3.000	Median :13.00	Median :13.00
Mean : 4.834	Mean : 3.589	Mean :13.63	Mean :13.45
3rd Qu.: 6.000	3rd Qu.: 5.000	3rd Qu.:16.00	3rd Qu.:16.00
Max. :15.000	Max. :11.000	Max. :26.00	Max. :27.00
HC	AC	HY	AY
Min. : 0.000	Min. : 0.000	Min. :0.000	Min. :0.000
1st Qu.: 4.000	1st Qu.: 2.000	1st Qu.:1.000	1st Qu.:2.000
Median : 5.000	Median : 4.000	Median :2.000	Median :3.000
Mean : 5.574	Mean : 4.021	Mean :2.529	Mean :2.642
3rd Qu.: 7.000	3rd Qu.: 6.000	3rd Qu.:4.000	3rd Qu.:3.000
Max. :15.000	Max. :12.000	Max. :8.000	Max. :7.000
HR	AR	B365H	B365D
Min. :0.00000	Min. :0.0000	Min. : 1.080	Min. : 2.870
1st Qu.:0.00000	1st Qu.:0.0000	1st Qu.: 1.660	1st Qu.: 3.300
Median :0.00000	Median :0.0000	Median : 2.120	Median : 3.500
Mean :0.08684	Mean :0.1211	Mean : 2.596	Mean : 3.996
3rd Qu.:0.00000	3rd Qu.:0.0000	3rd Qu.: 2.800	3rd Qu.: 4.000
Max. :1.00000	Max. :2.0000	Max. :17.000	Max. :11.000
B365A	BWH	BWD	BWA
Min. : 1.160	Min. : 1.060	Min. : 2.900	Min. : 1.190
1st Qu.: 2.547	1st Qu.: 1.670	1st Qu.: 3.300	1st Qu.: 2.600
Median : 3.500	Median : 2.150	Median : 3.500	Median : 3.500
Mean : 4.790	Mean : 2.579	Mean : 3.991	Mean : 4.745
3rd Qu.: 5.062	3rd Qu.: 2.800	3rd Qu.: 4.000	3rd Qu.: 5.250
Max. :29.000	Max. :15.000	Max. :12.000	Max. :36.000
IWH	IWD	IWA	PSH
Min. : 1.070	Min. : 2.850	Min. : 1.200	Min. : 1.080
1st Qu.: 1.700	1st Qu.: 3.300	1st Qu.: 2.600	1st Qu.: 1.700
Median : 2.150	Median : 3.500	Median : 3.450	Median : 2.180
Mean : 2.553	Mean : 3.943	Mean : 4.587	Mean : 2.639
3rd Qu.: 2.763	3rd Qu.: 4.000	3rd Qu.: 4.950	3rd Qu.: 2.840
Max. :13.000	Max. :13.000	Max. :28.000	Max. :19.070
PSD	PSA	WHH	WHD
Min. : 2.990	Min. : 1.180	Min. : 1.050	Min. : 2.500
1st Qu.: 3.357	1st Qu.: 2.652	1st Qu.: 1.700	1st Qu.: 3.300
Median : 3.640	Median : 3.575	Median : 2.150	Median : 3.500

Mean : 4.133	Mean : 4.994	Mean : 2.564	Mean : 3.997
3rd Qu.: 4.170	3rd Qu.: 5.230	3rd Qu.: 2.800	3rd Qu.: 4.000
Max. :13.220	Max. :36.830	Max. :17.000	Max. :13.000
WHA	VCH	VCD	VCA
Min. : 1.150	Min. : 1.060	Min. : 3.000	Min. : 1.18
1st Qu.: 2.587	1st Qu.: 1.700	1st Qu.: 3.300	1st Qu.: 2.60
Median : 3.500	Median : 2.150	Median : 3.600	Median : 3.60
Mean : 4.779	Mean : 2.627	Mean : 4.097	Mean : 5.00
3rd Qu.: 5.000	3rd Qu.: 2.800	3rd Qu.: 4.200	3rd Qu.: 5.20
Max. :34.000	Max. :21.000	Max. :13.000	Max. :41.00
Bb1X2	BbMxH	BbAvH	BbMxD
Min. :31.00	Min. : 1.100	Min. : 1.070	Min. : 3.040
1st Qu.:34.00	1st Qu.: 1.750	1st Qu.: 1.690	1st Qu.: 3.420
Median :36.00	Median : 2.250	Median : 2.160	Median : 3.735
Mean :36.13	Mean : 2.739	Mean : 2.582	Mean : 4.251
3rd Qu.:38.00	3rd Qu.: 2.913	3rd Qu.: 2.792	3rd Qu.: 4.250
Max. :41.00	Max. :21.000	Max. :16.550	Max. :15.000
BbAvD	BbMxA	BbAvA	Bb0U
Min. : 2.920	Min. : 1.200	Min. : 1.170	Min. :28.00
1st Qu.: 3.288	1st Qu.: 2.750	1st Qu.: 2.620	1st Qu.:32.00
Median : 3.550	Median : 3.695	Median : 3.495	Median :34.00
Mean : 4.005	Mean : 5.361	Mean : 4.763	Mean :33.84
3rd Qu.: 4.032	3rd Qu.: 5.370	3rd Qu.: 5.043	3rd Qu.:35.00
Max. :12.430	Max. :52.000	Max. :33.380	Max. :39.00
BbMx.2.5	BbAv.2.5	BbMx.2.5.1	BbAv.2.5.1
Min. :1.200	Min. :1.170	Min. :1.420	Min. :1.380
1st Qu.:1.710	1st Qu.:1.650	1st Qu.:1.710	1st Qu.:1.650
Median :2.000	Median :1.940	Median :1.950	Median :1.870
Mean :2.029	Mean :1.947	Mean :2.116	Mean :2.018
3rd Qu.:2.315	3rd Qu.:2.230	3rd Qu.:2.303	3rd Qu.:2.210
Max. :3.200	Max. :2.890	Max. :5.250	Max. :4.740
BbAH	BbAHh	BbMxAHH	BbAvAHH
Min. :15.00	Min. : -3.0000	Min. :1.560	Min. :1.520
1st Qu.:19.00	1st Qu.: -1.0000	1st Qu.:1.850	1st Qu.:1.800
Median :20.00	Median : -0.2500	Median :2.030	Median :1.970
Mean :19.88	Mean : -0.4033	Mean :2.055	Mean :1.992
3rd Qu.:21.00	3rd Qu.: 0.2500	3rd Qu.:2.200	3rd Qu.:2.130
Max. :24.00	Max. : 2.0000	Max. :3.270	Max. :3.020
BbMxAHA	BbAvAHA	PSCH	PSCD
Min. :1.450	Min. :1.410	Min. : 1.070	Min. : 2.860
1st Qu.:1.800	1st Qu.:1.750	1st Qu.: 1.698	1st Qu.: 3.310
Median :1.950	Median :1.890	Median : 2.190	Median : 3.610
Mean :1.972	Mean :1.915	Mean : 2.726	Mean : 4.102
3rd Qu.:2.130	3rd Qu.:2.070	3rd Qu.: 2.970	3rd Qu.: 4.202
Max. :2.850	Max. :2.670	Max. :18.040	Max. :14.910
PSCA			
Min. : 1.190			
1st Qu.: 2.612			
Median : 3.645			
Mean : 5.100			
3rd Qu.: 5.575			
Max. :36.030			

Div

Date

Time

HomeTeam

Length:380	Length:380	Length:380	Length:380
Class :character	Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character	Mode :character

AwayTeam	FTHG	FTAG	FTR
Length:380	Min. :0.000	Min. :0.000	Length:380
Class :character	1st Qu.:1.000	1st Qu.:0.000	Class :character
Mode :character	Median :1.000	Median :1.000	Mode :character
	Mean :1.437	Mean :1.042	
	3rd Qu.:2.000	3rd Qu.:2.000	
	Max. :6.000	Max. :5.000	

HTHG	HTAG	HTR	HS
Min. :0.0000	Min. :0.00	Length:380	Min. : 3.00
1st Qu.:0.0000	1st Qu.:0.00	Class :character	1st Qu.: 9.00
Median :0.0000	Median :0.00	Mode :character	Median :12.00
Mean :0.6026	Mean :0.45		Mean :12.46
3rd Qu.:1.0000	3rd Qu.:1.00		3rd Qu.:15.00
Max. :4.0000	Max. :3.00		Max. :25.00

AS	HST	AST	HF
Min. : 1.00	Min. : 0.000	Min. : 0.000	Min. : 4.00
1st Qu.: 7.00	1st Qu.: 3.000	1st Qu.: 2.000	1st Qu.:11.00
Median :10.00	Median : 4.000	Median : 3.000	Median :13.00
Mean :10.14	Mean : 4.337	Mean : 3.511	Mean :13.66
3rd Qu.:12.25	3rd Qu.: 6.000	3rd Qu.: 5.000	3rd Qu.:16.00
Max. :24.00	Max. :17.000	Max. :12.000	Max. :28.00

AF	HC	AC	HY
Min. : 5.00	Min. : 0.000	Min. : 0.000	Min. :0.000
1st Qu.:11.00	1st Qu.: 3.000	1st Qu.: 2.750	1st Qu.:1.000
Median :13.00	Median : 5.000	Median : 4.000	Median :2.000
Mean :13.79	Mean : 5.042	Mean : 4.195	Mean :2.547
3rd Qu.:16.00	3rd Qu.: 7.000	3rd Qu.: 6.000	3rd Qu.:4.000
Max. :30.00	Max. :14.000	Max. :12.000	Max. :7.000

AY	HR	AR	B365H
Min. :0.000	Min. :0.0	Min. :0.0000	Min. : 1.120
1st Qu.:2.000	1st Qu.:0.0	1st Qu.:0.0000	1st Qu.: 1.700
Median :2.000	Median :0.0	Median :0.0000	Median : 2.200
Mean :2.584	Mean :0.1	Mean :0.1263	Mean : 2.595
3rd Qu.:4.000	3rd Qu.:0.0	3rd Qu.:0.0000	3rd Qu.: 2.900
Max. :8.000	Max. :2.0	Max. :2.0000	Max. :10.000

B365D	B365A	BWH	BWD
Min. :2.800	Min. : 1.280	Min. : 1.120	Min. :2.700
1st Qu.:3.200	1st Qu.: 2.500	1st Qu.: 1.700	1st Qu.:3.200
Median :3.400	Median : 3.500	Median : 2.200	Median :3.400
Mean :3.805	Mean : 4.465	Mean : 2.599	Mean :3.813
3rd Qu.:4.000	3rd Qu.: 5.062	3rd Qu.: 2.900	3rd Qu.:4.000
Max. :9.500	Max. :21.000	Max. :10.000	Max. :9.500

BWA	IWH	IWD	IWA
Min. : 1.280	Min. :1.130	Min. :2.750	Min. : 1.280
1st Qu.: 2.550	1st Qu.:1.730	1st Qu.:3.188	1st Qu.: 2.550
Median : 3.500	Median :2.200	Median :3.400	Median : 3.450
Mean : 4.438	Mean :2.603	Mean :3.770	Mean : 4.378
3rd Qu.: 5.250	3rd Qu.:2.913	3rd Qu.:4.000	3rd Qu.: 5.000
Max. :20.000	Max. :9.900	Max. :8.800	Max. :19.500

PSH	PSD	PSA	WHH
Min. : 1.120	Min. :2.780	Min. : 1.290	Min. : 1.110
1st Qu.: 1.720	1st Qu.:3.230	1st Qu.: 2.600	1st Qu.: 1.700
Median : 2.260	Median :3.515	Median : 3.520	Median : 2.225
Mean : 2.650	Mean :3.894	Mean : 4.673	Mean : 2.616
3rd Qu.: 2.958	3rd Qu.:4.088	3rd Qu.: 5.230	3rd Qu.: 2.900
Max. :10.020	Max. :9.950	Max. :25.500	Max. :10.000
NA's :2	NA's :2	NA's :2	

WHD	WHA	VCH	VCD
Min. :2.800	Min. : 1.270	Min. : 1.100	Min. :2.800
1st Qu.:3.200	1st Qu.: 2.550	1st Qu.: 1.700	1st Qu.:3.200
Median :3.400	Median : 3.450	Median : 2.200	Median :3.500
Mean :3.802	Mean : 4.623	Mean : 2.582	Mean :3.831
3rd Qu.:4.000	3rd Qu.: 5.250	3rd Qu.: 2.885	3rd Qu.:4.025
Max. :9.000	Max. :26.000	Max. :10.500	Max. :9.500

VCA	MaxH	MaxD	MaxA
Min. : 1.250	Min. : 1.160	Min. : 2.900	Min. : 1.320
1st Qu.: 2.500	1st Qu.: 1.778	1st Qu.: 3.340	1st Qu.: 2.678
Median : 3.400	Median : 2.310	Median : 3.600	Median : 3.625
Mean : 4.453	Mean : 2.757	Mean : 4.019	Mean : 4.951
3rd Qu.: 5.000	3rd Qu.: 3.055	3rd Qu.: 4.202	3rd Qu.: 5.500
Max. :26.000	Max. :11.000	Max. :10.500	Max. :31.000

AvgH	AvgD	AvgA	B365.2.5
Min. :1.120	Min. :2.780	Min. : 1.280	Min. :1.280
1st Qu.:1.718	1st Qu.:3.210	1st Qu.: 2.550	1st Qu.:1.800
Median :2.220	Median :3.435	Median : 3.455	Median :2.100
Mean :2.608	Mean :3.813	Mean : 4.483	Mean :2.108
3rd Qu.:2.917	3rd Qu.:4.022	3rd Qu.: 5.093	3rd Qu.:2.500
Max. :9.910	Max. :9.160	Max. :21.610	Max. :3.400

B365.2.5.1	P.2.5	P.2.5.1	Max.2.5
Min. :1.330	Min. :1.310	Min. :1.370	Min. :1.310
1st Qu.:1.530	1st Qu.:1.810	1st Qu.:1.570	1st Qu.:1.850
Median :1.720	Median :2.145	Median :1.770	Median :2.175
Mean :1.867	Mean :2.162	Mean :1.912	Mean :2.196
3rd Qu.:2.000	3rd Qu.:2.520	3rd Qu.:2.098	3rd Qu.:2.553
Max. :3.750	Max. :3.340	Max. :3.640	Max. :3.400
	NA's :2	NA's :2	

Max.2.5.1	Avg.2.5	Avg.2.5.1	AHh
Min. :1.380	Min. :1.260	Min. :1.350	Min. : -2.5000
1st Qu.:1.610	1st Qu.:1.780	1st Qu.:1.560	1st Qu.: -0.7500
Median :1.820	Median :2.080	Median :1.750	Median : -0.2500
Mean :1.950	Mean :2.099	Mean :1.869	Mean : -0.3289

3rd Qu.:2.132	3rd Qu.:2.440	3rd Qu.:2.040	3rd Qu.: 0.0000
Max. :3.950	Max. :3.160	Max. :3.680	Max. : 1.7500

B365AHH	B365AHA	PAHH	PAHA
Min. :1.670	Min. :1.650	Min. :1.750	Min. :1.680
1st Qu.:1.900	1st Qu.:1.890	1st Qu.:1.890	1st Qu.:1.880
Median :1.970	Median :1.960	Median :1.970	Median :1.950
Mean :1.963	Mean :1.954	Mean :1.966	Mean :1.954
3rd Qu.:2.040	3rd Qu.:2.030	3rd Qu.:2.040	3rd Qu.:2.030
Max. :2.200	Max. :2.160	Max. :2.310	Max. :2.200
NA's :10	NA's :10	NA's :2	NA's :2

MaxAHH	MaxAHA	AvgAHH	AvgAHA
Min. :1.800	Min. :1.710	Min. :1.740	Min. :1.670
1st Qu.:1.920	1st Qu.:1.910	1st Qu.:1.870	1st Qu.:1.860
Median :1.990	Median :1.980	Median :1.940	Median :1.930
Mean :1.995	Mean :1.988	Mean :1.939	Mean :1.932
3rd Qu.:2.070	3rd Qu.:2.060	3rd Qu.:2.010	3rd Qu.:2.000
Max. :2.330	Max. :2.250	Max. :2.270	Max. :2.170

B365CH	B365CD	B365CA	BWCH
Min. : 1.100	Min. : 2.700	Min. : 1.250	Min. :1.100
1st Qu.: 1.700	1st Qu.: 3.200	1st Qu.: 2.600	1st Qu.:1.715
Median : 2.150	Median : 3.400	Median : 3.550	Median :2.200
Mean : 2.598	Mean : 3.857	Mean : 4.628	Mean :2.603
3rd Qu.: 2.870	3rd Qu.: 4.000	3rd Qu.: 5.250	3rd Qu.:2.900
Max. :11.000	Max. :10.000	Max. :26.000	Max. :9.750

BWCD	BWCA	IWCH	IWCD
Min. : 2.750	Min. : 1.28	Min. : 1.120	Min. :2.700
1st Qu.: 3.200	1st Qu.: 2.60	1st Qu.: 1.730	1st Qu.:3.150
Median : 3.400	Median : 3.50	Median : 2.225	Median :3.400
Mean : 3.817	Mean : 4.55	Mean : 2.609	Mean :3.747
3rd Qu.: 4.000	3rd Qu.: 5.25	3rd Qu.: 2.900	3rd Qu.:4.000
Max. :10.000	Max. :23.00	Max. :11.000	Max. :9.000

IWCA	PSCH	PSCD	PSCA
Min. : 1.250	Min. : 1.100	Min. : 2.710	Min. : 1.270
1st Qu.: 2.600	1st Qu.: 1.720	1st Qu.: 3.188	1st Qu.: 2.688
Median : 3.500	Median : 2.275	Median : 3.480	Median : 3.640
Mean : 4.368	Mean : 2.672	Mean : 3.900	Mean : 4.873
3rd Qu.: 5.100	3rd Qu.: 2.975	3rd Qu.: 4.062	3rd Qu.: 5.440
Max. :20.000	Max. :10.930	Max. :11.520	Max. :28.530

WHCH	WHCD	WHCA	VCCH
Min. : 1.080	Min. : 2.620	Min. : 1.250	Min. : 1.080
1st Qu.: 1.700	1st Qu.: 3.200	1st Qu.: 2.600	1st Qu.: 1.722
Median : 2.225	Median : 3.400	Median : 3.600	Median : 2.225
Mean : 2.647	Mean : 3.827	Mean : 4.793	Mean : 2.600
3rd Qu.: 2.900	3rd Qu.: 4.000	3rd Qu.: 5.250	3rd Qu.: 2.880
Max. :11.000	Max. :11.000	Max. :26.000	Max. :10.500

VCCD	VCCA	MaxCH	MaxCD
Min. : 2.750	Min. : 1.250	Min. : 1.130	Min. : 2.860
1st Qu.: 3.200	1st Qu.: 2.600	1st Qu.: 1.788	1st Qu.: 3.320

Median : 3.450	Median : 3.400	Median : 2.355	Median : 3.610
Mean : 3.845	Mean : 4.549	Mean : 2.836	Mean : 4.062
3rd Qu.: 4.000	3rd Qu.: 5.050	3rd Qu.: 3.105	3rd Qu.: 4.242
Max. :10.500	Max. :26.000	Max. :13.000	Max. :12.400

MaxCA	AvgCH	AvgCD	AvgCA
Min. : 1.320	Min. : 1.100	Min. : 2.710	Min. : 1.280
1st Qu.: 2.743	1st Qu.: 1.710	1st Qu.: 3.167	1st Qu.: 2.618
Median : 3.870	Median : 2.235	Median : 3.430	Median : 3.545
Mean : 5.215	Mean : 2.625	Mean : 3.824	Mean : 4.630
3rd Qu.: 5.750	3rd Qu.: 2.908	3rd Qu.: 4.032	3rd Qu.: 5.282
Max. :31.370	Max. :10.390	Max. :10.410	Max. :24.600

B365C.2.5	B365C.2.5.1	PC.2.5	PC.2.5.1	MaxC.2.5
Min. :1.220	Min. :1.30	Min. :1.220	Min. :1.320	Min. :1.260
1st Qu.:1.720	1st Qu.:1.53	1st Qu.:1.795	1st Qu.:1.570	1st Qu.:1.857
Median :2.100	Median :1.72	Median :2.125	Median :1.790	Median :2.190
Mean :2.142	Mean :1.87	Mean :2.188	Mean :1.922	Mean :2.241
3rd Qu.:2.500	3rd Qu.:2.10	3rd Qu.:2.530	3rd Qu.:2.110	3rd Qu.:2.560
Max. :3.500	Max. :4.33	Max. :3.720	Max. :4.520	Max. :3.720

MaxC.2.5.1	AvgC.2.5	AvgC.2.5.1	AHCh
Min. :1.330	Min. :1.220	Min. :1.290	Min. : -2.7500
1st Qu.:1.627	1st Qu.:1.760	1st Qu.:1.550	1st Qu.: -0.7500
Median :1.840	Median :2.080	Median :1.750	Median : -0.2500
Mean :1.997	Mean :2.118	Mean :1.878	Mean : -0.3329
3rd Qu.:2.223	3rd Qu.:2.440	3rd Qu.:2.062	3rd Qu.: 0.0000
Max. :4.610	Max. :3.520	Max. :4.130	Max. : 1.7500

B365CAHH	B365CAHA	PCAHH	PCAHA
Min. :1.700	Min. :1.670	Min. :1.750	Min. :1.750
1st Qu.:1.880	1st Qu.:1.880	1st Qu.:1.880	1st Qu.:1.880
Median :1.960	Median :1.960	Median :1.960	Median :1.960
Mean :1.959	Mean :1.956	Mean :1.962	Mean :1.959
3rd Qu.:2.040	3rd Qu.:2.040	3rd Qu.:2.040	3rd Qu.:2.040
Max. :2.160	Max. :2.160	Max. :2.200	Max. :2.210

MaxCAHH	MaxCAHA	AvgCAHH	AvgCAHA
Min. :1.780	Min. :1.800	Min. :1.72	Min. :1.750
1st Qu.:1.940	1st Qu.:1.930	1st Qu.:1.86	1st Qu.:1.860
Median :2.020	Median :2.020	Median :1.93	Median :1.940
Mean :2.021	Mean :2.016	Mean :1.94	Mean :1.938
3rd Qu.:2.100	3rd Qu.:2.100	3rd Qu.:2.02	3rd Qu.:2.010
Max. :2.260	Max. :2.270	Max. :2.15	Max. :2.180

```
#Ahora seleccionaremos únicamente las columnas Date, HomeTeam, AwayTeam,
# FTHG, FTAG y FTR en cada uno de los data frames. Primero guardaremos los
#data frames en una lista con nombre lista y después con ayuda de las funciones
#lapply y select (del paquete dplyr), seleccionaremos las columnas deseadas.
#Los nuevos data frames quedarán guardados en nlista.
lista <- list(d1718, d1819, d1920)
nlista <- lapply(lista, select, Date, HomeTeam, AwayTeam, FTHG, FTAG, FTR)
```

```
#Con las funciones lapply y str observaremos la estructura de nuestros nuevos data frames
lapply(nlista, str)
```

```
'data.frame': 380 obs. of 6 variables:
 $ Date : chr "18/08/17" "18/08/17" "19/08/17" "19/08/17" ...
 $ HomeTeam: chr "Leganes" "Valencia" "Celta" "Girona" ...
 $ AwayTeam: chr "Alaves" "Las Palmas" "Sociedad" "Ath Madrid" ...
 $ FTHG : int 1 1 2 2 1 0 2 0 1 0 ...
 $ FTAG : int 0 0 3 2 1 0 0 3 0 1 ...
 $ FTR : chr "H" "H" "A" "D" ...
'data.frame': 380 obs. of 6 variables:
 $ Date : chr "17/08/2018" "17/08/2018" "18/08/2018" "18/08/2018" ...
 $ HomeTeam: chr "Betis" "Girona" "Barcelona" "Celta" ...
 $ AwayTeam: chr "Levante" "Valladolid" "Alaves" "Espanol" ...
 $ FTHG : int 0 0 3 1 1 1 2 1 2 1 ...
 $ FTAG : int 3 0 0 1 2 2 0 4 1 1 ...
 $ FTR : chr "A" "D" "H" "D" ...
'data.frame': 380 obs. of 6 variables:
 $ Date : chr "16/08/2019" "17/08/2019" "17/08/2019" "17/08/2019" ...
 $ HomeTeam: chr "Ath Bilbao" "Celta" "Valencia" "Mallorca" ...
 $ AwayTeam: chr "Barcelona" "Real Madrid" "Sociedad" "Eibar" ...
 $ FTHG : int 1 1 1 2 0 4 1 0 1 1 ...
 $ FTAG : int 0 3 1 1 1 4 0 2 2 0 ...
 $ FTR : chr "H" "A" "D" "H" ...
```

```
[[1]]
NULL
```

```
[[2]]
NULL
```

```
[[3]]
NULL
```

```
#Arreglamos las columnas Date para que R reconozca los elementos como fechas,
# esto lo hacemos con las funciones mutate (paquete dplyr) y as.Date.
```

```
nlista[[1]] <- mutate(nlista[[1]], Date = as.Date(Date, "%d/%m/%y"))
nlista[[2]] <- mutate(nlista[[2]], Date = as.Date(Date, "%d/%m/%Y"))
nlista[[3]] <- mutate(nlista[[3]], Date = as.Date(Date, "%d/%m/%Y"))
```

```
#Verificamos que nuestros cambios se hayan llevado a cabo
lapply(nlista, str)
```

```
'data.frame': 380 obs. of 6 variables:
 $ Date : Date, format: "2017-08-18" "2017-08-18" ...
 $ HomeTeam: chr "Leganes" "Valencia" "Celta" "Girona" ...
 $ AwayTeam: chr "Alaves" "Las Palmas" "Sociedad" "Ath Madrid" ...
 $ FTHG : int 1 1 2 2 1 0 2 0 1 0 ...
 $ FTAG : int 0 0 3 2 1 0 0 3 0 1 ...
 $ FTR : chr "H" "H" "A" "D" ...
'data.frame': 380 obs. of 6 variables:
 $ Date : Date, format: "2018-08-17" "2018-08-17" ...
```



```

$ HomeTeam: chr "Betis" "Girona" "Barcelona" "Celta" ...
$ AwayTeam: chr "Levante" "Valladolid" "Alaves" "Espanol" ...
$ FTHG : int 0 0 3 1 1 1 2 1 2 1 ...
$ FTAG : int 3 0 0 1 2 2 0 4 1 1 ...
$ FTR : chr "A" "D" "H" "D" ...
'data.frame': 380 obs. of 6 variables:
 $ Date : Date, format: "2019-08-16" "2019-08-17" ...
 $ HomeTeam: chr "Ath Bilbao" "Celta" "Valencia" "Mallorca" ...
 $ AwayTeam: chr "Barcelona" "Real Madrid" "Sociedad" "Eibar" ...
 $ FTHG : int 1 1 1 2 0 4 1 0 1 1 ...
 $ FTAG : int 0 3 1 1 1 4 0 2 2 0 ...
 $ FTR : chr "H" "A" "D" "H" ...

```

```
[[1]]
NULL
```

```
[[2]]
NULL
```

```
[[3]]
NULL
```

```

#Finalmente, con ayuda de las funciones rbind y do.call
#combinamos los data frames contenidos en nlista como un único data frame
data <- do.call(rbind, nlista)
dim(data)

```

```
[1] 1140 6
```

```
str(data)
```

```

'data.frame': 1140 obs. of 6 variables:
 $ Date : Date, format: "2017-08-18" "2017-08-18" ...
 $ HomeTeam: chr "Leganes" "Valencia" "Celta" "Girona" ...
 $ AwayTeam: chr "Alaves" "Las Palmas" "Sociedad" "Ath Madrid" ...
 $ FTHG : int 1 1 2 2 1 0 2 0 1 0 ...
 $ FTAG : int 0 0 3 2 1 0 0 3 0 1 ...
 $ FTR : chr "H" "H" "A" "D" ...

```

```
tail(data)
```

	Date	HomeTeam	AwayTeam	FTHG	FTAG	FTR
1135	2020-07-19	Espanol	Celta	0	0	D
1136	2020-07-19	Granada	Ath Bilbao	4	0	H
1137	2020-07-19	Leganes	Real Madrid	2	2	D
1138	2020-07-19	Levante	Getafe	1	0	H
1139	2020-07-19	Osasuna	Mallorca	2	2	D
1140	2020-07-19	Sevilla	Valencia	1	0	H

```

View(data)
summary(data)

```

Date	HomeTeam	AwayTeam	FTHG
Min. :2017-08-18	Length:1140	Length:1140	Min. :0.000
1st Qu.:2018-03-17	Class :character	Class :character	1st Qu.:1.000
Median :2019-01-16	Mode :character	Mode :character	Median :1.000
Mean :2019-01-15			Mean :1.479
3rd Qu.:2019-10-27			3rd Qu.:2.000
Max. :2020-07-19			Max. :8.000

FTAG	FTR
Min. :0.000	Length:1140
1st Qu.:0.000	Class :character
Median :1.000	Mode :character
Mean :1.108	
3rd Qu.:2.000	
Max. :6.000	

```
#Con ayuda de la función table obtenemos las estimaciones
# de probabilidades solicitadas
(pcasa <- round(table(data$FTHG)/dim(data)[1], 3)) # Probabilidades marginales
```

```
      0      1      2      3      4      5      6      7      8
0.232 0.327 0.267 0.112 0.035 0.019 0.005 0.001 0.001
```

```
#estimadas para los equipos que juegan en casa
```

```
(pvisita <- round(table(data$FTAG)/dim(data)[1], 3)) # Probabilidades marginales
```

```
      0      1      2      3      4      5      6
0.352 0.340 0.212 0.054 0.029 0.010 0.003
```

```
#estimadas para los equipos que juegan como visitante
```

```
(pcta <- round(table(data$FTHG, data$FTAG)/dim(data)[1], 3)) # Probabilidades
```

```
      0      1      2      3      4      5      6
0 0.078 0.081 0.046 0.018 0.005 0.004 0.000
1 0.116 0.115 0.068 0.018 0.009 0.002 0.000
2 0.088 0.094 0.061 0.011 0.009 0.002 0.002
3 0.045 0.032 0.025 0.006 0.002 0.002 0.001
4 0.014 0.011 0.007 0.000 0.004 0.000 0.000
5 0.009 0.005 0.004 0.000 0.001 0.000 0.000
6 0.003 0.002 0.000 0.001 0.000 0.000 0.000
7 0.000 0.001 0.000 0.000 0.000 0.000 0.000
8 0.000 0.000 0.001 0.000 0.000 0.000 0.000
```

```
# conjuntas estimadas para los partidos
```

```
#Con la función apply primero dividimos cada elemento de las columnas de la
#matriz de probabilidades conjuntas, por las probabilidades marginales asociadas
#y que corresponden al equipo de casa. Note como hemos definido una función anónima
```

```
# dentro de apply. Luego dividimos cada elemento de las filas de la matriz que resulta,
# por las probabilidades marginales asociadas y que corresponden al equivo visitante.
# Finalmente hacemos obtenemos la transpuesta de la matriz que resulta. Esta última matriz,
# es la matriz de cocientes buscada, es decir, hemos dividido cada probabilidad conjunta,
# por el producto de probabilidades marginales correspondientes.
(cocientes <- apply(pcta, 2, function(col) col/pcasa))
```

	0	1	2	3	4	5	6
0	0.3362069	0.3491379	0.1982759	0.07758621	0.02155172	0.017241379	0.000000000
1	0.3547401	0.3516820	0.2079511	0.05504587	0.02752294	0.006116208	0.000000000
2	0.3295880	0.3520599	0.2284644	0.04119850	0.03370787	0.007490637	0.007490637
3	0.4017857	0.2857143	0.2232143	0.05357143	0.01785714	0.017857143	0.008928571
4	0.4000000	0.3142857	0.2000000	0.00000000	0.11428571	0.000000000	0.000000000
5	0.4736842	0.2631579	0.2105263	0.00000000	0.05263158	0.000000000	0.000000000
6	0.6000000	0.4000000	0.0000000	0.20000000	0.00000000	0.000000000	0.000000000
7	0.0000000	1.0000000	0.0000000	0.00000000	0.00000000	0.000000000	0.000000000
8	0.0000000	0.0000000	1.0000000	0.00000000	0.00000000	0.000000000	0.000000000

```
(cocientes <- apply(cocientes, 1, function(fila) fila/pvisita))
```

	0	1	2	3	4	5	6
0	0.9551332	1.0077843	0.9363296	1.1414367	1.1363636	1.3456938	1.704545
1	1.0268763	1.0343587	1.0354704	0.8403361	0.9243697	0.7739938	1.176471
2	0.9352635	0.9809013	1.0776624	1.0528976	0.9433962	0.9930487	0.000000
3	1.4367816	1.0193680	0.7629352	0.9920635	0.0000000	0.0000000	3.703704
4	0.7431629	0.9490668	1.1623402	0.6157635	3.9408867	1.8148820	0.000000
5	1.7241379	0.6116208	0.7490637	1.7857143	0.0000000	0.0000000	0.000000
6	0.0000000	0.0000000	2.4968789	2.9761905	0.0000000	0.0000000	0.000000

	7	8
0	0.000000	0.000000
1	2.941176	0.000000
2	0.000000	4.716981
3	0.000000	0.000000
4	0.000000	0.000000
5	0.000000	0.000000
6	0.000000	0.000000

```
(cocientes <- t(cocientes))
```

	0	1	2	3	4	5	6
0	0.9551332	1.0268763	0.9352635	1.4367816	0.7431629	1.7241379	0.000000
1	1.0077843	1.0343587	0.9809013	1.0193680	0.9490668	0.6116208	0.000000
2	0.9363296	1.0354704	1.0776624	0.7629352	1.1623402	0.7490637	2.496879
3	1.1414367	0.8403361	1.0528976	0.9920635	0.6157635	1.7857143	2.976190
4	1.1363636	0.9243697	0.9433962	0.0000000	3.9408867	0.0000000	0.000000
5	1.3456938	0.7739938	0.9930487	0.0000000	1.8148820	0.0000000	0.000000
6	1.7045455	1.1764706	0.0000000	3.7037037	0.0000000	0.0000000	0.000000
7	0.0000000	2.9411765	0.0000000	0.0000000	0.0000000	0.0000000	0.000000
8	0.0000000	0.0000000	4.7169811	0.0000000	0.0000000	0.0000000	0.000000

*#Lo anterior igual lo pudimos lograr de la siguiente manera:*

```
pcta/outer(pcasa, pvisita, "*")
```

	0	1	2	3	4	5	6
0	0.9551332	1.0268763	0.9352635	1.4367816	0.7431629	1.7241379	0.0000000
1	1.0077843	1.0343587	0.9809013	1.0193680	0.9490668	0.6116208	0.0000000
2	0.9363296	1.0354704	1.0776624	0.7629352	1.1623402	0.7490637	2.4968789
3	1.1414367	0.8403361	1.0528976	0.9920635	0.6157635	1.7857143	2.9761905
4	1.1363636	0.9243697	0.9433962	0.0000000	3.9408867	0.0000000	0.0000000
5	1.3456938	0.7739938	0.9930487	0.0000000	1.8148820	0.0000000	0.0000000
6	1.7045455	1.1764706	0.0000000	3.7037037	0.0000000	0.0000000	0.0000000
7	0.0000000	2.9411765	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000
8	0.0000000	0.0000000	4.7169811	0.0000000	0.0000000	0.0000000	0.0000000

*#Primero extraemos de manera aleatoria algunas filas de nuestro data*

*# frame data, esto lo hacemos con ayuda de la función sample.*

```
set.seed(2)
```

```
indices <- sample(dim(data)[1], size = 380, replace = TRUE)
```

```
newdata <- data[indices, ]
```

*#Con ayuda de la función table obtenemos las estimaciones de probabilidades*

```
(pcasa <- round(table(newdata$FTHG)/dim(newdata)[1], 3)) # Probabilidades marginales
```

	0	1	2	3	4	5	6
0.261	0.311	0.274	0.084	0.045	0.018	0.008	

*# estimadas para los equipos que juegan en casa*

```
(pvisita <- round(table(newdata$FTAG)/dim(newdata)[1], 3)) # Probabilidades
```

	0	1	2	3	4	5	6
0.361	0.400	0.187	0.034	0.008	0.008	0.003	

*#marginales estimadas para los equipos que juegan como visitante*

```
(pcta <- round(table(newdata$FTHG, newdata$FTAG)/dim(newdata)[1], 3)) # Probabilidades
```

	0	1	2	3	4	5	6
0	0.103	0.100	0.039	0.011	0.000	0.008	0.000
1	0.113	0.139	0.045	0.008	0.005	0.000	0.000
2	0.082	0.103	0.074	0.011	0.003	0.000	0.003
3	0.029	0.034	0.016	0.005	0.000	0.000	0.000
4	0.018	0.018	0.008	0.000	0.000	0.000	0.000
5	0.008	0.005	0.005	0.000	0.000	0.000	0.000
6	0.008	0.000	0.000	0.000	0.000	0.000	0.000

```
#conjuntas estimadas para los partidos
```

```
#Obtenemos nuevamente los cocientes de probabilidades conjuntas entre probabilidades marginales
```

```
(cocientes <- pcta/outer(pcasa, pvisita, "*"))
```

	0	1	2	3	4	5	6
0	1.0931746	0.9578544	0.7990657	1.2395763	0.0000000	3.8314176	0.0000000
1	1.0064932	1.1173633	0.7737676	0.7565727	2.0096463	0.0000000	0.0000000
2	0.8290030	0.9397810	1.4442406	1.1807643	1.3686131	0.0000000	3.6496350
3	0.9563382	1.0119048	1.0185893	1.7507003	0.0000000	0.0000000	0.0000000
4	1.1080332	1.0000000	0.9506833	0.0000000	0.0000000	0.0000000	0.0000000
5	1.2311480	0.6944444	1.4854427	0.0000000	0.0000000	0.0000000	0.0000000
6	2.7700831	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000

```
#Repita el remuestreo anterior varias veces (unas 1000 veces)
```

```
# y obtenga una idea de las distribuciones de los cocientes.
```

```
#Finalmente mencione en cuales casos le parece razonable la suposición de que
```

```
#el cociente es igual a 1.
```